
Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Anderson Tonello Bringhenti^{1*}; Juliano Schimiguel

¹ Mestre em Engenharia Mecânica pela Universidade Federal de Santa Catarina, Florianópolis, SC, Brasil.

² Doutorado em Ciências da Computação. Av. Pádua Dias, 11 – São Dimas; 13418-900, Piracicaba, SP, Brasil

Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Resumo

O trabalho tem como objetivo investigar a aplicação conjunta de modelos de Large Language Models (LLMs) e grafos na análise de comunicações do Federal Reserve, com foco na identificação de sinais relacionados à orientação da política monetária. Foi utilizado como fontes documentos oficiais do Federal Reserve, por exemplo comunicados do FOMC, atas de reuniões, discursos, testemunhos e comunicados à imprensa. Inicialmente, foram coletados mais 1.200 links de comunicações públicas a partir do site oficial do FED, seguidos pela extração e preparação dos textos em formato estruturado. Em seguida, modelos de linguagem generativos foram utilizados para extrair sinais monetários e classificá-los em categorias de postura monetária, variando de dovish à hawkish. A partir dessa classificação cada sinal foi associado à uma pontuação numérica e um vetor de embedding, permitindo o cálculo de similaridade semântica usando similaridade de cosseno entre os vetores. A partir dessas informações, foi construída um grafo, composto por publicações, datas, sinais monetários e relações semânticas entre sinais. Os resultados

Palavras-chave: Federal Reserve; política monetária; modelos de linguagem; grafos; processamento de linguagem natural.

1 Introdução

A comunicação dos bancos centrais desempenha papel fundamental na formação das expectativas dos agentes econômicos e na transmissão da política monetária, pois informações sobre as perspectivas econômicas e as trajetórias futuras dos juros podem influenciar as decisões dos participantes do mercado (Woodford, 2005). No caso do Federal Reserve (Fed), essa comunicação ocorre em documentos como comunicados e atas do Federal Open Market Committee (FOMC), discursos de seus dirigentes e outros materiais institucionais. Essas divulgações são acompanhadas por participantes do mercado e pesquisadores interessados em identificar sinais sobre a orientação futura da política monetária (Blinder *et al.*, 2008). Além das decisões correntes sobre a taxa de juros, os mercados também reagem às informações dos comunicados do FOMC sobre a trajetória futura da política monetária (Gürkaynak *et al.*, 2005).

A interpretação dessas comunicações, contudo, é dificultada pelo volume de documentos e pela complexidade de sua linguagem. Métodos baseados em dicionários genéricos podem ser limitados em documentos financeiros, pois o significado dos termos depende do contexto (Loughran e McDonald, 2011). Surge, assim, o desafio de analisar de forma estruturada e automatizada os conteúdos produzidos pelo Fed, gerando subsídios para a compreensão e antecipação da política monetária.

Esse desafio insere-se no uso de documentos textuais como fontes de informação quantitativa para a investigação de fenômenos econômicos (Gentzkow *et al.*, 2019). Avanços em processamento de linguagem natural (*Natural Language Processing* - NLP), especialmente os modelos de linguagem de grande porte (*Large Language Models* - LLMs), ampliaram a análise automatizada de textos complexos, permitindo realizar diferentes tarefas a partir de instruções e exemplos fornecidos em contexto (Brown *et al.*, 2020).

De forma específica, Hansen e Kazinnik (2024) avalia a capacidade de modelos GPT de interpretar a linguagem técnica do Fed e classificar a orientação de comunicados do FOMC. Em comparação com avaliações humanas e métodos tradicionais, os modelos apresentam desempenho superior, reforçando seu potencial para capturar nuances semânticas e identificar sinais de orientação expansionista ou restritiva.

De modo semelhante, Silva *et al.* (2025) utiliza LLMs para classificar comunicações de diferentes bancos centrais segundo tópico, orientação monetária e sentimento. A partir dessas classificações, os autores constroem medidas quantitativas e investigam sua relação com mudanças futuras na política monetária, demonstrando a possibilidade de transformar informações qualitativas em indicadores.

Paralelamente, técnicas de análise de grafos permitem representar relações que não são observadas quando os elementos são considerados isoladamente. Nessa estrutura, os nós representam os elementos de interesse e as conexões descrevem suas relações, possibilitando investigar proximidade, centralidade e comunidades (Needham e Hodler, 2019).

Neste estudo, os sinais de política monetária identificados nas comunicações do Fed são representados em um grafo com base em suas relações de similaridade semântica. Essa representação permite examinar a orientação de cada sinal, sua posição na rede, as associações entre sinais semelhantes e a formação de agrupamentos recorrentes. Para

isso, a análise avalia a conectividade da rede, identifica comunidades e calcula medidas de centralidade.

O algoritmo de componentes fracamente conectados (*weakly connected components* – WCC) identifica subconjuntos de nós que permanecem conectados quando a direção das relações é desconsiderada (Needham e Hodler, 2019). No presente estudo, o algoritmo é empregado para verificar a conectividade global da rede e orientar a definição do limiar de similaridade semântica, evitando que a análise subsequente seja realizada sobre grupos isolados de sinais.

Para identificar esses agrupamentos, emprega-se o algoritmo de Leiden, um método de detecção de comunidades que otimiza uma função de qualidade da partição e assegura que as comunidades obtidas sejam bem conectadas internamente. Essa propriedade permite separar conjuntos de sinais com maior similaridade semântica entre si, favorecendo a identificação de temas ou padrões recorrentes na comunicação monetária (Traag *et al.*, 2019).

A centralidade de intermediação (*betweenness centrality*) quantifica a frequência com que um nó se encontra nos caminhos geodésicos entre outros pares de nós. Na rede de sinais, essa medida destaca observações que podem conectar grupos semanticamente distintos e, portanto, ocupar uma posição de intermediação na estrutura relacional (Freeman, 1977).

A centralidade de grau ponderado mensura a intensidade das conexões de cada nó a partir dos pesos associados às suas arestas. Nesse caso, a força de um nó pode ser representada pela soma dos pesos de suas conexões, permitindo distinguir nós conectados por relações de maior intensidade (Barrat *et al.*, 2004). Neste estudo, essa medida permite atribuir maior relevância aos sinais associados a relações semanticamente mais fortes.

O PageRank estima a importância relativa de um nó ao considerar não somente suas conexões, mas também a importância dos nós aos quais ele está ligado (Page *et al.*, 1999). Aplicado à rede ponderada de similaridade, o algoritmo permite destacar sinais conectados a outros sinais estruturalmente relevantes, oferecendo uma ponderação relacional adicional para os indicadores de orientação monetária.

Embora estudos recentes demonstrem o potencial dos modelos de linguagem para interpretar e quantificar a comunicação de bancos centrais, permanece menos explorada sua utilização conjunta com métodos de análise de grafos para investigar as relações entre sinais monetários. Assim, este estudo avalia se essa combinação contribui para a construção de um indicador experimental da orientação da política monetária do Fed, examinando sua capacidade de sintetizar padrões das comunicações e sua relação com decisões posteriores do FOMC.

2 Material e Métodos

Este estudo possui abordagem qualitativa e quantitativa e caráter exploratório, uma vez que busca avaliar a viabilidade de um procedimento para transformar comunicações do Federal Reserve (Fed) em sinais estruturados de orientação monetária e investigar sua relação com decisões posteriores de política monetária. De acordo com (Gil, 2010), pesquisas exploratórias contribuem para tornar o problema investigado mais explícito e possibilitam a construção e avaliação inicial de hipóteses.

O procedimento foi organizado em sete etapas principais: coleta e preparação das comunicações do Federal Reserve; extração e classificação dos sinais monetários por modelo de linguagem; geração das representações vetoriais; construção das redes de similaridade semântica; cálculo dos indicadores de orientação monetária; obtenção das decisões de taxa de juros; e avaliação estatística e temporal dos indicadores.

2.1 Coleta e preparação dos documentos

O conjunto textual utilizado foi composto por comunicações oficiais publicadas pelo Federal Reserve, incluindo comunicados das reuniões do Federal Open Market Committee (FOMC), atas, discursos de dirigentes, testemunhos e comunicados à imprensa. Os documentos foram obtidos a partir do site oficial da instituição.

A coleta partiu de páginas institucionais que concentram links para os documentos do Federal Reserve, incluindo os materiais de política monetária, o calendário do FOMC e as páginas de discursos e testemunhos. Nas páginas com navegação paginada, a coleta dos endereços eletrônicos foi realizada com Selenium. Para o calendário do FOMC foram utilizadas requisições HTTP por meio da biblioteca Requests e interpretação do conteúdo HTML com BeautifulSoup.

Após a obtenção dos endereços, cada publicação foi processada individualmente. Nos documentos disponibilizados diretamente em HTML, foram removidos elementos sem interesse analítico, como `script`, `style`, `noscript`, `header` e `footer`. O conteúdo restante foi convertido em texto e submetido a tratamento para remoção de espaços excedentes e linhas vazias.

Quando o conteúdo estava disponível em PDF, o arquivo correspondente foi identificado a partir dos hiperlinks presentes na página, baixado temporariamente e processado com a biblioteca PyPDF2. O texto foi extraído sequencialmente de suas páginas e concatenado em um único conteúdo textual.

Para cada publicação, foram armazenados a URL de origem, o título, a data de publicação e o conteúdo textual. O título e a data foram identificados com auxílio de um modelo de linguagem e a data foi padronizada no formato YYYY-MM-DD. Os resultados foram armazenados incrementalmente em formato JSON, permitindo evitar o processamento repetido de documentos já extraídos.

2.2 Extração e classificação dos sinais monetários

A partir dos documentos estruturados, foi utilizado um modelo de linguagem de grande porte para identificar sinais relacionados à política monetária. O modelo recebeu como contexto o título da publicação, sua data e o conteúdo textual, juntamente com um *prompt* estruturado no qual era instruído a atuar como um economista especializado na análise de comunicações de bancos centrais.

Cada sinal identificado foi classificado em uma das cinco categorias de orientação monetária: *dovish*, *mostly dovish*, *neutral*, *mostly hawkish* e *hawkish*. As definições consideraram principalmente informações relacionadas à inflação, à atividade econômica, ao mercado de trabalho e às implicações dessas condições para a orientação da política monetária.

Para cada sinal, o modelo retornou três informações: o conteúdo sintetizado do sinal (*signal*), uma justificativa para a classificação (*justification*) e um trecho da comunicação original utilizado como evidência (*evidence*). Cada sinal deveria representar uma única ideia principal, e categorias sem sinais relevantes eram retornadas como listas vazias. O *prompt* completo utilizado nessa etapa é apresentado no Apêndice I.

Após a extração, as categorias textuais foram convertidas deterministicamente em uma escala numérica de orientação monetária:

$$s_i = \begin{cases} -1, & \text{dovish,} \\ -0,5, & \text{mostly dovish,} \\ 0, & \text{neutral,} \\ 0,5, & \text{mostly hawkish,} \\ 1, & \text{hawkish.} \end{cases}$$

Dessa forma, valores negativos representam orientação relativamente mais expansionista e valores positivos representam orientação relativamente mais restritiva.

2.3 Representação vetorial e construção do grafo

Para representar semanticamente os sinais extraídos, o conteúdo do campo *signal* foi fornecido ao modelo *text-embedding-3-large*. Cada sinal foi convertido em um vetor de *embedding* com 3.072 componentes, armazenado na propriedade *embedding_signal*. Esses vetores foram posteriormente utilizados no cálculo da proximidade semântica entre os sinais.

Os dados foram armazenados no Neo4j utilizando dois tipos principais de nós: *Publication*, representando as comunicações do Federal Reserve, e *Signal*, representando individualmente os sinais monetários extraídos. Os nós *Publication* foram identificados pela URL do documento e ligados aos respectivos nós *Signal* por relações *HAS_SIGNAL*.

Os nós *Signal* armazenaram, entre outras informações, sua classificação, pontuação numérica, justificativa, evidência, data de publicação e *embedding*. Relações *SIMILAR_TO* foram utilizadas para representar a proximidade semântica entre os sinais, sendo o valor da similaridade armazenado na propriedade *score_similarity*.

Como a similaridade semântica não possui uma direção natural, as relações SIMILAR_T0 foram tratadas como não direcionadas nas projeções utilizadas pelos algoritmos de análise de grafos.

2.4 Definição dos períodos e construção das redes de similaridade

As análises foram realizadas separadamente para os intervalos compreendidos entre duas reuniões consecutivas do FOMC. As datas utilizadas como delimitadores foram obtidas a partir das publicações cujo título correspondia a *Federal Reserve issues FOMC statement*. Após a remoção de duplicidades, as datas foram ordenadas cronologicamente.

Para duas datas consecutivas, t_i e t_{i+1} , foram selecionados os sinais publicados no intervalo

$$t_i \leq d_j < t_{i+1},$$

em que d_j corresponde à data de publicação do sinal j . Dessa forma, as comunicações publicadas na data inicial são incorporadas ao período, enquanto aquelas publicadas na data da reunião subsequente são excluídas. Essa delimitação foi adotada para preservar a ordem temporal entre as informações utilizadas na construção do indicador e a decisão do FOMC utilizada posteriormente como referência.

Para cada período, os nós selecionados foram projetados em memória utilizando o Neo4j Graph Data Science (GDS). Sobre os vetores de *embedding*, foi aplicado o algoritmo *k-nearest neighbors* (KNN), com similaridade do cosseno e máximo de 50 vizinhos por nó ($\text{topK} = 50$). As relações selecionadas pelo algoritmo foram persistidas como SIMILAR_T0, utilizando a similaridade calculada como peso.

Foram avaliadas duas estratégias para definição do limiar mínimo de similaridade.

Na primeira, denominada abordagem de limiar variável, o procedimento foi iniciado com limiar igual a 0,80. Após a construção da rede, foi aplicado o algoritmo de componentes fracamente conectadas (*Weakly Connected Components* – WCC). Quando mais de uma componente era identificada, o limiar era reduzido em 0,01 e a rede reconstruída. O procedimento era repetido até que todos os nós do período pertencessem a uma única componente conexa ou até que fosse atingido o limite mínimo de 0,10. Dessa forma, foi mantido para cada período o maior limiar testado capaz de produzir uma rede conectada.

Na segunda estratégia, foi utilizado um único limiar para todos os períodos. Esse valor foi definido a partir da mediana dos limiares obtidos no procedimento variável. O procedimento resultou em um limiar fixo igual a 0,72, posteriormente utilizado para reconstruir todas as redes sob um mesmo critério de similaridade.

A comparação entre as duas estratégias permitiu avaliar a sensibilidade dos indicadores à forma utilizada para definir as relações semânticas.

2.5 Construção dos indicadores de orientação monetária

Após a construção de cada rede, foram calculadas medidas destinadas a incorporar a posição estrutural dos sinais à agregação de suas pontuações monetárias. Foram utilizados

o algoritmo de Leiden para detecção de comunidades e três medidas de centralidade: centralidade de intermediação (*betweenness centrality*), centralidade de grau ponderado e PageRank.

Como medida de referência, foi calculada a média simples das pontuações dos sinais:

$$I_{\text{média},t} = \frac{1}{N_t} \sum_{i=1}^{N_t} s_i,$$

em que N_t representa o número de sinais existentes no período t .

Para cada medida de centralidade c_i , foi também calculada uma média ponderada:

$$I_{c,t} = \frac{\sum_{i=1}^{N_t} s_i c_i}{\sum_{i=1}^{N_t} c_i}.$$

Esse procedimento originou três indicadores, ponderados respectivamente pela centralidade de intermediação, centralidade de grau e PageRank.

O algoritmo de Leiden foi aplicado utilizando a similaridade semântica como peso das relações. Inicialmente, calculou-se a média da orientação monetária dos sinais em cada comunidade. Em seguida, essas médias foram agregadas com pesos iguais:

$$I_{\text{Leiden},t} = \frac{1}{K_t} \sum_{k=1}^{K_t} \left(\frac{1}{N_{k,t}} \sum_{i \in C_{k,t}} s_i \right),$$

em que K_t representa o número de comunidades no período, $C_{k,t}$ a comunidade k e $N_{k,t}$ seu número de sinais.

Foram ainda construídas três medidas combinando comunidades e centralidade. Para cada comunidade, a pontuação foi inicialmente ponderada por uma das medidas de centralidade:

$$I_{k,c,t} = \frac{\sum_{i \in C_{k,t}} s_i c_i}{\sum_{i \in C_{k,t}} c_i}.$$

Posteriormente, os resultados das comunidades foram agregados com pesos iguais:

$$I_{\text{Leiden},c,t} = \frac{1}{K_t} \sum_{k=1}^{K_t} I_{k,c,t}.$$

Ao todo, foram calculadas oito formas de agregação: média simples; três indicadores ponderados pelas centralidades; média das comunidades de Leiden; e três indicadores que combinam comunidades de Leiden e centralidade. Os mesmos procedimentos foram aplicados às redes construídas com limiar variável e com limiar fixo.

2.6 Obtenção das decisões da *Federal Funds Rate*

As decisões de política monetária utilizadas como referência foram obtidas por meio da API do Federal Reserve Economic Data (FRED). Foram utilizadas as séries DFEDTARL e DFEDTARU, correspondentes, respectivamente, aos limites inferior e superior da faixa-alvo da *Federal Funds Rate*.

Como a unidade temporal da análise corresponde às reuniões do FOMC, foram selecionadas apenas as observações cujas datas coincidiam com os comunicados utilizados para delimitar os períodos.

A mudança na política de juros foi representada pela variação do limite superior da faixa-alvo entre duas reuniões consecutivas:

$$\Delta r_t = r_t^U - r_{t-1}^U,$$

em que r_t^U corresponde ao limite superior da faixa-alvo na reunião t . Valores positivos representam elevação da faixa-alvo, valores negativos representam redução e valores iguais a zero representam manutenção.

Para avaliar a relação prospectiva entre as comunicações e a política monetária, o indicador construído a partir dos sinais pertencentes ao intervalo entre t_i e t_{i+1} foi associado à decisão observada na data t_{i+1} .

2.7 Avaliação estatística e temporal dos indicadores

A avaliação dos indicadores foi realizada em etapas complementares, buscando distinguir associação estatística, capacidade explicativa e desempenho preditivo.

Inicialmente, foram calculados os coeficientes de correlação de Pearson e Spearman entre cada indicador e a variação subsequente da faixa-alvo da *Federal Funds Rate*. O coeficiente de Pearson foi utilizado para medir a associação linear, enquanto o coeficiente de Spearman foi empregado para avaliar associações monotônicas sem pressupor linearidade.

Em seguida, foi estimado separadamente para cada indicador um modelo de regressão linear da forma

$$\Delta r_{t+1} = \alpha + \beta I_t + \varepsilon_t,$$

em que I_t corresponde ao indicador produzido a partir das comunicações do período anterior à decisão. Os erros-padrão foram estimados utilizando o procedimento HAC de Newey-West, robusto à heterocedasticidade e à autocorrelação, com uma defasagem.

Como análise complementar, os indicadores também foram relacionados à decisão observada no início de cada intervalo. Essa comparação permitiu avaliar se sua associação era mais intensa com a decisão subsequente do que com a orientação de política monetária já vigente.

2.7.1 Avaliação do valor incremental da estrutura do grafo

Para investigar se as informações provenientes da estrutura da rede acrescentam capacidade explicativa ou preditiva à classificação individual dos sinais, foi utilizada a média simples como modelo de referência:

$$M_0 : \quad \Delta r_{t+1} = \alpha + \beta_1 I_t^{\text{média}} + \varepsilon_t.$$

Esse modelo foi comparado com uma especificação contendo adicionalmente um dos indicadores derivados do grafo:

$$M_1 : \quad \Delta r_{t+1} = \alpha + \beta_1 I_t^{\text{média}} + \beta_2 I_t^{\text{grafo}} + \varepsilon_t.$$

O ganho incremental foi avaliado considerando conjuntamente o aumento do coeficiente de determinação ajustado, a significância estatística do coeficiente β_2 com erros-padrão HAC e a redução do erro de previsão fora da amostra.

2.7.2 Validação temporal fora da amostra

Por fim, a capacidade preditiva foi avaliada utilizando uma estratégia de validação temporal com janela expansiva. As primeiras 30 reuniões foram utilizadas como conjunto inicial de estimação. A partir desse ponto, o modelo foi utilizado para prever a decisão da reunião seguinte. Após cada previsão, a observação realizada era incorporada ao conjunto de treinamento e o modelo era novamente estimado, preservando a ordem cronológica dos dados.

O desempenho das previsões foi avaliado por meio do erro absoluto médio (*Mean Absolute Error* – MAE), da raiz do erro quadrático médio (*Root Mean Squared Error* – RMSE) e da capacidade de identificar a direção da decisão.

Para a avaliação da direção, variações superiores a 0,125 ponto percentual foram classificadas como aumento, variações inferiores a -0,125 ponto percentual como redução e os valores compreendidos entre esses limites como manutenção.

Como referência, foi utilizado um modelo simples no qual a previsão para a reunião seguinte corresponde à média histórica das variações da taxa disponíveis até aquele momento. A comparação com esse modelo permitiu avaliar se os indicadores extraídos das comunicações acrescentavam informação preditiva em relação a uma referência baseada apenas no histórico das próprias decisões.

3 Resultados

Nesta seção são apresentados os resultados obtidos nas principais etapas do estudo: coleta das comunicações públicas do Federal Reserve, preparação dos textos, extração e classificação dos sinais de política monetária por modelos de linguagem, construção da rede de similaridade semântica, definição do indicador e validação da sua capacidade de refletir a orientação da política monetária.

Além de descrever o conjunto de dados e os sinais identificados, são analisadas as propriedades da rede construída, incluindo a distribuição das conexões, a formação de comunidades e a relevância estrutural dos nós. Por fim, os resultados são organizados temporalmente para avaliar a relação entre a orientação dos sinais extraídos e as decisões observadas do Federal Open Market Committee (FOMC).

3.1 Coleta dos links das publicações

Na etapa inicial da pesquisa, foram coletados, usando Python, os links referentes às comunicações públicas disponibilizadas pelo Federal Reserve em seu site oficial. Ao todo, foram obtidos 1.310 links. O objetivo foi estruturar as origens da base documental à ser utilizada nas etapas de extração textual e classificação dos sinais de política monetária.

Foram consideradas páginas relacionadas aos materiais de política monetária, ao calendário do Federal Open Market Committee (FOMC) e às comunicações públicas de dirigentes, como discursos e testemunhos. Os endereços apresentados na Tabela 1 correspondem a páginas institucionais de consulta que reúnem links para os textos integrais das publicações, e não aos documentos individuais que compõem a base. Em particular, o Calendário do FOMC disponibiliza os links para as atas e os comunicados associados a cada reunião do Comitê. A partir dessas páginas, foram extraídos os links das comunicações publicadas entre janeiro de 2015 e setembro de 2025.

Tabela 1. Páginas do Federal Reserve utilizadas como fontes iniciais para a coleta.

Fonte consultada	Endereço eletrônico
Materiais de política monetária	https://www.federalreserve.gov/monetarypolicy/materials/
Calendário do FOMC	https://www.federalreserve.gov/monetarypolicy/fomccalendars.htm
Discursos e testemunhos	https://www.federalreserve.gov/newsevents/speeches-testimony.htm

Fonte: Autoria própria.

O procedimento de coleta dos links combinou ferramentas distintas de acordo com a estrutura de cada página. Para os materiais de política monetária e para as páginas de discursos e testemunhos, que houve necessidade de navegação paginada, foi utilizado a biblioteca Selenium com o navegador Microsoft Edge. Essa ferramenta permitiu carregar as páginas, avançar entre os resultados e identificar os elementos HTML que continham os links das publicações. Já no calendário do FOMC, foram realizadas requisições HTTP com a biblioteca Requests, seguidas da análise do código HTML com BeautifulSoup.

3.2 Extração e padronização dos textos

Após a obtenção dos endereços eletrônicos das publicações, foi realizada a etapa de extração e padronização de seu conteúdo textual. Os resultados foram armazenados em formato JSON, mantendo-se, para cada publicação processada, a URL de origem, o título, a data de publicação e o texto extraído. Antes do processamento de um novo endereço, eram verificadas as URLs já presentes no conjunto de dados, evitando o processamento repetido de publicações previamente extraídas.

Para as publicações disponibilizadas diretamente em páginas HTML, foram realizadas requisições HTTP por meio da biblioteca *Requests*. As requisições foram configuradas com tempo limite de resposta e, após o recebimento do conteúdo, sua codificação foi definida como UTF-8. O documento HTML retornado foi então interpretado utilizando a biblioteca *Beautiful Soup*.

Antes da obtenção do texto, foram removidos elementos HTML sem interesse para a análise, especificamente as tags `script`, `style`, `noscript`, `header`, `footer` e `nav`. Em seguida, o conteúdo restante da página foi convertido em texto, utilizando quebras de linha como separadores. Cada linha foi posteriormente tratada para remoção de espaços excedentes em suas extremidades, e as linhas vazias foram descartadas. O resultado desse procedimento constituiu o conteúdo textual utilizado nas etapas seguintes do trabalho.

A identificação do título e da data de publicação foi realizada com auxílio de um modelo de linguagem de grande escala. O texto obtido após o tratamento da página HTML foi fornecido ao modelo juntamente com uma instrução para retornar essas duas informações em formato JSON. A data de publicação foi padronizada no formato YYYY-MM-DD. Após o processamento, a URL original e o conteúdo textual previamente extraído eram incorporados ao registro, resultando em uma estrutura padronizada para cada publicação.

Para documentos cujo conteúdo estava disponibilizado em arquivos PDF, foi adotado um procedimento específico. Inicialmente, a página associada à publicação era obtida por meio de uma requisição HTTP e processada com *Beautiful Soup*. Todas as tags de hiperlink `<a>` eram examinadas e seus atributos `href` avaliados para identificar endereços contendo a extensão `.pdf`.

Após a identificação do arquivo, uma nova requisição HTTP era realizada para seu download. O documento era armazenado temporariamente como arquivo PDF e processado com a biblioteca *PyPDF2*. A extração era realizada sequencialmente, percorrendo todas as páginas do documento por meio da classe `PdfReader` e concatenando o conteúdo textual obtido. Após a conclusão da leitura, o arquivo temporário era removido.

Durante a preparação, os documentos cujo título continha a expressão *implementation note* foram marcados como não extraídos, em vez de terem seu conteúdo utilizado nas etapas seguintes. Ao final de cada processamento, o registro era acrescentado ao arquivo JSON, que era atualizado incrementalmente. Esse procedimento permitiu preservar os dados já coletados e retomar a execução sem duplicar publicações.

Como resultado da etapa de extração, cada comunicação passou a ser representada em uma estrutura padronizada, contendo quatro campos principais: `url`, `title`, `text` e `publication_date`, conforme ilustrado na Figura 1.

```
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128a.htm",
  "title": "Federal Reserve issues FOMC statement",
  "text": "Available indicators suggest that economic activity has been expanding at a solid pace. Job gains have remained lo",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/monetarypolicy/fomcpressconf20260128.htm",
  "title": "January 27-28, 2026 FOMC Meeting",
  "text": "January 28, 2026 Chair Powell 's Press Conference FINAL \n \nPage 1 of 24 \n Transcript of Chair Powell 's P",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128b.htm",
  "title": "Federal Open Market Committee reaffirms its \"Statement on Longer-Run Goals and Monetary Policy Strategy\"",
  "text": "1 \n \nStatement on Longer -Run Goals and \nMonetary Policy Strategy \nAdopted effective January 24, 2012; as rea",
  "publication_date": "2026-01-28"
},
}
```

Figura 1. Exemplo da estrutura JSON produzida na etapa de extração dos textos.
Fonte: Autoria própria.

3.3 Extração e classificação dos sinais monetários

Após a estruturação da base textual, foi realizada a etapa de identificação e classificação dos sinais de política monetária presentes nas comunicações do Federal Reserve. Para essa finalidade, foi utilizado um modelo de linguagem de grande porte, instruído por meio de um prompt estruturado a atuar como um economista especializado na análise de comunicações de bancos centrais e de sinais relacionados à política monetária.

Para cada documento, o prompt recebeu como contexto três informações provenientes da etapa anterior: o título da publicação, a data de publicação e o conteúdo textual da comunicação. A partir dessas informações, o modelo gpt-5.6-terra foi instruído a identificar somente sinais relacionados à política monetária e a classificar cada sinal de acordo com a orientação monetária implícita. A execução foi configurada para produzir respostas estruturadas em formato JSON, com temperatura igual a zero e sem esforço adicional de raciocínio.

Foram definidas cinco categorias de orientação monetária: *dovish*, *mostly dovish*, *neutral*, *mostly hawkish* e *hawkish*. As definições incorporadas ao prompt consideraram principalmente informações relacionadas à inflação, à atividade econômica, ao mercado de trabalho e à orientação esperada da política monetária. Os critérios utilizados são apresentados na Tabela 2.

Tabela 2. Descrição das classes para classificação dos sinais monetários.

Classe	Descrição
<i>dovish</i>	Clearly supports monetary easing or maintaining an accommodative stance. Use when the signal indicates that inflation is at target, below target, or moving sustainably toward target; economic activity is weakening; or labor market conditions are softening in a way that reduces the need for restrictive policy.
<i>mostly dovish</i>	Leans toward monetary easing or delaying further tightening, but it is not definitive. Use when the signal reports progress on inflation, slower growth, or softer labor market conditions, while also mentioning uncertainty.
<i>neutral</i>	The signal does not clearly imply either easing or tightening. Use when it does not indicate a dominant direction for policy. Do not classify as neutral merely because it is factual or descriptive.
<i>mostly hawkish</i>	Leans toward monetary tightening or delaying easing, but it is not definitive. Use when the signal reports elevated inflation, upside inflation risks, resilient demand, or strong labor market conditions, while also mentioning uncertainty.
<i>hawkish</i>	Clearly supports monetary tightening or maintaining a restrictive stance. Use when the signal indicates that inflation is above target, persistent, broad-based, or rising; economic activity remains strong; or labor market conditions remain tight in a way that justifies restrictive policy.

Fonte: Autoria própria.

Além das definições das classes, o prompt estabeleceu regras para tornar a extração mais consistente. Foram considerados apenas sinais relacionados à política monetária, e cada sinal deveria representar uma única ideia principal. Para cada classificação, o modelo deveria retornar uma lista de sinais identificados, sendo utilizada uma lista vazia quando nenhum sinal correspondente fosse encontrado no documento.

A saída esperada foi definida como um objeto JSON organizado pelas cinco categorias de classificação. Para cada sinal identificado, foram retornados três campos:

- *signal*: síntese da principal informação ou sinal de política monetária identificado;
- *justification*: breve justificativa para a classificação atribuída;
- *evidence*: trecho curto, reproduzido diretamente da comunicação original, utilizado como evidência para o sinal identificado.

O prompt completo utilizado nessa etapa é apresentado no Apêndice 4.

Na próxima etapa, cada sinal foi convertido em um registro individual. A classificação textual foi então associada a um escore numérico por meio de um mapeamento determinístico, independente do modelo de linguagem. Os valores variam de -1 , correspondente à orientação mais *dovish*, a 1 , correspondente à orientação mais *hawkish*, conforme apresentado na Tabela 3.

Além da classificação e do escore, foi gerada uma representação vetorial para cada sinal extraído. Para isso, somente o conteúdo do campo *signal* foi fornecido ao

Tabela 3. Mapa da classificação para o escore.

Classificação	Escore
<i>dovish</i>	-1
<i>mostly_dovish</i>	-0,5
<i>neutral</i>	0
<i>mostly_hawkish</i>	0,5
<i>hawkish</i>	1

Fonte: Autoria própria.

modelo de embeddings text-embedding-3-large. Cada sinal foi representado por um vetor com 3.072 componentes, armazenado no campo `embedding_signal`. Esses vetores foram posteriormente utilizados para representar a proximidade semântica entre os sinais monetários e constituir as relações de similaridade empregadas na construção do grafo.

Ao final do processamento, cada sinal monetário passou a corresponder a uma linha da base tabular, contendo os campos `url`, `title`, `publication_date`, `classification`, `score`, `signal`, `justification`, `evidence` e `embedding_signal`. Os novos registros eram concatenados aos resultados já existentes e armazenados incrementalmente em arquivo CSV, permitindo preservar os sinais previamente processados e retomar a execução sem duplicação de documentos.

3.4 Construção do grafo

Após a estruturação e classificação dos sinais monetários, os dados foram inseridos em um banco de dados orientado a grafos utilizando o Neo4j. A modelagem adotada foi composta por dois tipos de nós: `Publication`, utilizado para representar cada comunicação do Federal Reserve, e `Signal`, utilizado para representar individualmente os sinais de política monetária extraídos dessas comunicações.

Os nós `Publication` foram identificados de forma única pela URL da publicação. Para cada nó, foram armazenadas as propriedades `title` e `publication_date`, correspondentes, respectivamente, ao título e à data de publicação do documento. O uso da URL como identificador permitiu que diferentes sinais extraídos de uma mesma comunicação fossem associados a um único nó de publicação.

Os nós `Signal`, por sua vez, foram identificados pela combinação entre o conteúdo textual do sinal e a URL da publicação de origem. Dessa forma, sinais com conteúdos semelhantes ou mesmo idênticos, mas provenientes de documentos distintos, puderam ser mantidos como entidades independentes no grafo. Cada nó recebeu as propriedades `classification`, `score`, `justification`, `evidence`, `embedding_signal` e `date`. A propriedade `date` corresponde à data de publicação do documento do qual o sinal foi extraído.

A vinculação entre as publicações e os sinais foi representada pela relação `HAS_SIGNAL`, criada entre cada nó `Publication` e os respectivos nós `Signal`. Essa estrutura preserva a origem documental de cada sinal e, em conjunto com as propriedades `justification` e `evidence`, permite rastrear a classificação até o conteúdo da comunicação utilizada pelo modelo de linguagem.

Além das relações entre publicações e sinais, foram construídas relações `SIMILAR_TO` entre sinais semanticamente próximos. Essas conexões foram obtidas a partir da comparação dos vetores armazenados em `embedding_signal` e receberam a propriedade `score_similarity`, correspondente à similaridade entre os respectivos vetores. Como a proximidade semântica representa uma associação simétrica, a direção das relações foi desconsiderada nas projeções utilizadas nas análises de rede.

Diferentemente dos nós e das relações `HAS_SIGNAL`, que constituem a estrutura permanente do grafo, as relações `SIMILAR_TO` foram reconstruídas separadamente para cada período de análise. Antes do processamento de um novo período, as relações desse tipo existentes eram removidas e uma nova rede de similaridade era criada contendo apenas os sinais pertencentes ao intervalo temporal considerado. A definição desses períodos e o procedimento utilizado para estabelecer as conexões semânticas são apresentados na seção seguinte.

Essa estrutura é ilustrada na Figura 2.



Figura 2. Esquema dos nós e das relações utilizados na construção do grafo.
Fonte: Autoria própria.

3.5 Caracterização das redes por período

A construção das relações `SIMILAR_TO` foi realizada separadamente para cada intervalo de análise. Essa estratégia restringiu as comparações semânticas aos sinais associados ao mesmo período entre reuniões consecutivas do FOMC, evitando a formação de relações entre sinais pertencentes a contextos temporais distintos.

As datas que delimitam os períodos foram obtidas da base textual produzida nas etapas anteriores. Foram selecionadas as publicações cujo título correspondia exatamente a *Federal Reserve issues FOMC statement*, referentes aos comunicados oficiais divulgados após as reuniões do FOMC. As respectivas datas de publicação foram reunidas, eventuais duplicidades foram eliminadas e os valores foram ordenados cronologicamente.

A partir dessa sequência, cada intervalo foi definido por duas datas consecutivas de divulgação dos comunicados do FOMC. Para um período iniciado em t_i e encerrado em t_{i+1} , foram selecionados os nós `Signal` que possuíam a propriedade `embedding_signal` e cuja data satisfazia a condição

$$t_i \leq \text{data de publicação} < t_{i+1}.$$

Consequentemente, as comunicações publicadas na data inicial foram incluídas no período, enquanto aquelas divulgadas na data do comunicado subsequente foram excluídas. Essa definição evita que o indicador referente ao intervalo incorpore informações publicadas simultaneamente à decisão do FOMC utilizada posteriormente como referência para sua avaliação, preservando o caráter prospectivo da análise.

A quantidade de sinais monetários disponíveis para a construção da rede variou entre os períodos analisados, em função do número e do conteúdo das comunicações publicadas entre reuniões consecutivas do FOMC. A Figura 3 apresenta o número de nós *Signal* selecionados em cada intervalo. Cada nó corresponde a um sinal monetário extraído das comunicações publicadas entre a data inicial do período, inclusive, e a data do comunicado subsequente, exclusive.



Figura 3. Número de sinais monetários utilizados na construção da rede em cada período entre comunicados consecutivos do FOMC.

Fonte: Autoria própria.

A variação no número de nós evidencia que a quantidade de informações disponíveis para a construção das redes não é constante ao longo do tempo. Sendo que o mínimo de sinais disponíveis ocorre nas reuniões de realizadas no começo da pandemia de COVID-19.

Para cada intervalo, os sinais selecionados foram projetados temporariamente em memória por meio do Neo4j Graph Data Science (GDS). Na primeira projeção, denominada *signal-cypher*, foram incluídos apenas os nós *Signal* pertencentes ao período e a propriedade vetorial *embedding_signal*. Essa projeção não altera a estrutura persistida no banco de dados e foi utilizada exclusivamente como entrada para o cálculo das relações de similaridade.

Sobre essa projeção foi executado o algoritmo *k*-nearest neighbors (KNN). A comparação entre os sinais foi realizada utilizando a similaridade do cosseno aplicada aos vetores de *embedding*. Para cada nó, foram considerados no máximo 50 vizinhos semanticamente mais próximos (*topK* = 50), sujeitos também a um limiar mínimo de similaridade.

O procedimento retornou, para cada conexão selecionada, os identificadores dos dois nós e o respectivo valor de similaridade. Esses identificadores foram convertidos novamente nos nós Signal armazenados no Neo4j. Para impedir a criação duplicada de uma mesma associação, os pares foram filtrados de acordo com seus identificadores internos antes da persistência da relação. Para cada par mantido, foi criada uma relação SIMILAR_T0, e o valor calculado pelo KNN foi armazenado na propriedade `score_similarity`.

O limiar mínimo de similaridade foi determinado de forma adaptativa para cada período. O procedimento foi iniciado com valor igual a 0,80. Após a construção das relações, uma nova projeção, denominada `signal-wcc`, foi formada com os nós e as conexões daquele intervalo, considerando as relações como não direcionadas. Em seguida, foi aplicado o algoritmo de componentes fracamente conectadas (*Weakly Connected Components* - WCC) para determinar o número de componentes conexas existentes na rede.

Quando mais de uma componente era identificada, o limiar de similaridade era reduzido em 0,01 e as relações SIMILAR_T0 eram reconstruídas. O procedimento era repetido até que todos os nós do período pertencessem a uma única componente conexa ou até que fosse atingido o limite mínimo de 0,10. Dessa forma, para cada período foi selecionado o maior limiar, dentro da sequência testada, capaz de produzir uma rede conectada.

Esse procedimento procurou estabelecer um equilíbrio entre duas características da rede. Limiares elevados preservam apenas relações de maior proximidade semântica, porém podem produzir grupos isolados de sinais. A redução progressiva do limiar adiciona conexões menos semelhantes até que seja obtida uma estrutura conectada.

Ao final do procedimento, cada intervalo entre comunicados consecutivos do FOMC foi representado por uma rede semântica ponderada. Os nós correspondem aos sinais monetários identificados nas comunicações publicadas durante o período, enquanto as relações representam sua proximidade semântica e são ponderadas pela propriedade `score_similarity`. Essa representação constitui a entrada para os algoritmos de detecção de comunidades e de centralidade empregados na construção dos indicadores de orientação monetária.

Os limiares de similaridade obtidos pelo procedimento adaptativo variaram entre os períodos analisados, refletindo diferenças na estrutura semântica dos sinais disponíveis em cada intervalo. A Figura 4 apresenta o valor do limiar necessário para que a rede correspondente a cada período formasse uma única componente conexa.




Figura 4. Limiar de similaridade utilizado na construção da rede em cada período entre comunicados consecutivos do FOMC.

Fonte: Autoria própria.

Os resultados mostram que não foi necessário utilizar o mesmo nível mínimo de similaridade em todos os períodos para obter uma rede conectada. Um limiar mais elevado indica que os diferentes documentos apresentam pontos de vista mais próximos entre si, permitindo conectar os sinais com relações de maior proximidade semântica e preservando uma rede mais coesa quanto ao conteúdo abordado. Em contraste, um limiar mais baixo indica maior dispersão entre os pontos de vista expressos nos documentos: para formar uma única rede, foi necessário incorporar relações entre sinais progressivamente menos semelhantes. Assim, o limiar sintetiza o grau de convergência semântica necessário para conectar os sinais produzidos no período, sem representar diretamente a orientação favorável ou contrária da política monetária.

Além da abordagem com limiar de similaridade adaptativo, foi avaliada uma segunda configuração utilizando um limiar constante para todos os períodos. Para definir esse valor, foi calculada a mediana dos limiares de similaridade obtidos individualmente pelo procedimento adaptativo ao longo dos intervalos analisados. A mediana resultante foi igual a 0,72. Valor adotado como limiar fixo no segundo cenário. Essa escolha permite utilizar um valor representativo dos limiares requeridos para a formação das redes no procedimento adaptativo, ao mesmo tempo em que mantém constante o critério de conexão entre os sinais ao longo de toda a série temporal.

3.6 Construção dos indicadores

Após a construção da rede de similaridade semântica para cada período entre reuniões consecutivas do FOMC, foram calculadas diferentes versões do indicador de orientação monetária. Para isso, foram combinadas as pontuações atribuídas aos sinais monetários com informações estruturais extraídas do grafo. Foram utilizados o algoritmo de Leiden para detecção de comunidades e três medidas de centralidade: centralidade de intermediação (*betweenness centrality*), centralidade de grau (*degree centrality*) e PageRank.

Inicialmente, as três medidas de centralidade foram calculadas para cada nó Signal da rede. Os resultados foram associados por meio do identificador de cada nó, formando uma base contendo, para cada sinal, sua pontuação de orientação monetária (`node_score`) e os respectivos valores de centralidade.

Como referência, foi calculada a média simples das pontuações dos sinais pertencentes ao período. Esse indicador atribui o mesmo peso a todos os nós e, portanto, não incorpora informações sobre a posição de cada sinal na estrutura da rede. Sua expressão pode ser representada por

$$I_{\text{média}} = \frac{1}{N} \sum_{i=1}^N s_i,$$

em que s_i representa a pontuação de orientação monetária do sinal i e N corresponde ao número de sinais considerados no período.

Em seguida, foram construídos três indicadores utilizando as medidas de centralidade como fatores de ponderação. De forma geral, para uma medida de centralidade c_i , o indicador foi calculado por

$$I_c = \frac{\sum_{i=1}^N s_i c_i}{\sum_{i=1}^N c_i}.$$

A primeira ponderação utilizou a centralidade de intermediação. Essa medida destaca sinais que ocupam posições de intermediação na rede, isto é, nós que participam com maior frequência dos caminhos que conectam diferentes regiões do grafo. Dessa forma, sinais com maior centralidade de intermediação receberam maior peso na composição do indicador `betweenness_weighted_sentiment`.

A segunda versão utilizou a centralidade de grau ponderado. Nesse caso, o peso atribuído a cada sinal decorre da intensidade de suas conexões com os demais nós da rede, produzindo o indicador `degree_weighted_sentiment`. Essa abordagem atribui maior influência aos sinais que apresentam maior relevância local na estrutura de similaridade semântica.

A terceira ponderação foi realizada utilizando o PageRank. Essa medida considera a relevância estrutural do nó levando em conta não apenas suas próprias conexões, mas também a relevância dos nós aos quais ele está conectado. Os valores calculados pelo algoritmo foram utilizados como pesos das pontuações monetárias, resultando no indicador `pagerank_weighted_sentiment`.

As Figuras 5 e 6 apresentam a evolução temporal para Leiden e dos três indicadores ponderados por centralidade. A primeira corresponde às redes construídas com limiar de similaridade variável entre os períodos, enquanto a segunda utiliza o limiar fixo de 0,72.




Figura 5. Indicadores de orientação monetária obtidos usando Leiden e medidas de centralidade de intermediação, grau e PageRank para as redes construídas com limiar de similaridade variável.

Fonte: Autoria própria.




Figura 6. Indicadores de orientação monetária obtidos pela média simples e pelas medidas de centralidade de intermediação, grau e PageRank para as redes construídas com limiar fixo de similaridade igual a 0,72.

Fonte: Autoria própria.

Além dos indicadores calculados diretamente sobre todos os nós da rede, o algoritmo de Leiden foi utilizado para incorporar a estrutura de comunidades à agregação dos sinais. Para cada período, o algoritmo associou cada nó a uma comunidade, permitindo separar a rede em grupos de sinais semanticamente relacionados.

A primeira medida baseada em Leiden foi construída calculando-se, inicialmente, a média simples da pontuação dos sinais pertencentes a cada comunidade. Posteriormente, as médias das comunidades foram agregadas com pesos iguais, conforme

$$I_{\text{Leiden}} = \frac{1}{K} \sum_{k=1}^K \left(\frac{1}{N_k} \sum_{i \in C_k} s_i \right),$$

em que K representa o número de comunidades identificadas, C_k corresponde à comunidade k e N_k representa seu número de sinais. O resultado corresponde ao indicador `leiden_equal_weight_sentiment`. Esse procedimento faz com que cada comunidade contribua igualmente para o resultado final, independentemente de sua quantidade de nós.

Também foram construídas três versões que combinam a detecção de comunidades com as medidas de centralidade. Nesse procedimento, a ponderação pelas centralidades foi realizada inicialmente dentro de cada comunidade. Para uma medida de centralidade c , a orientação monetária da comunidade k foi calculada como

$$I_{k,c} = \frac{\sum_{i \in C_k} s_i c_i}{\sum_{i \in C_k} c_i}.$$

Após o cálculo individual para cada comunidade, os valores obtidos foram agregados por meio de uma média simples entre as comunidades:

$$I_{\text{Leiden},c} = \frac{1}{K} \sum_{k=1}^K I_{k,c}.$$

Dessa combinação resultaram três indicadores: um baseado na centralidade de intermediação, outro na centralidade de grau e o terceiro no PageRank. Em cada caso, a importância estrutural dos sinais é calculada dentro de cada comunidade. Posteriormente, os valores das comunidades são agregados por meio de uma média simples, de modo que todas recebam o mesmo peso no indicador final. Essa abordagem diferencia esses indicadores daqueles calculados diretamente sobre toda a rede.

As Figuras 7 e 8 apresentam os indicadores resultantes da incorporação das comunidades de Leiden ao processo de agregação. Novamente, são apresentados separadamente os resultados produzidos pelas redes construídas com limiar variável e com limiar fixo de similaridade.




Figura 7. Indicadores construídos a partir das comunidades identificadas pelo algoritmo de Leiden combinadas com as medidas de centralidade para as redes com limiar de similaridade variável.

Fonte: Autoria própria.




Figura 8. Indicadores construídos a partir das comunidades identificadas pelo algoritmo de Leiden combinadas com as medidas de centralidade para as redes com limiar fixo de similaridade igual a 0,72.

Fonte: Autoria própria.

Ao todo, foram obtidas oito formas de agregação da orientação monetária em cada período: a média simples; três indicadores ponderados diretamente pelas centralidades de intermediação, grau e PageRank; o indicador de comunidades de Leiden com pesos iguais; e três indicadores que combinam Leiden com as respectivas medidas de centralidade. Essa estrutura permite comparar uma agregação que utiliza exclusivamente as classificações individuais com diferentes formas de incorporação da organização estrutural e semântica da rede. Além disso, os mesmos algoritmos e procedimentos de cálculo foram utilizados nas duas estratégias de construção das redes consideradas neste trabalho.

3.7 Obtenção da *Federal Funds Rate*

Para avaliar a relação entre os indicadores de orientação monetária e as decisões posteriores do Federal Open Market Committee (FOMC), foram obtidas informações referentes à faixa-alvo da *Federal Funds Rate*. Os dados foram consultados por meio da API do Federal Reserve Economic Data (FRED), utilizando duas séries temporais: DFEDTARL, correspondente ao limite inferior da faixa-alvo, e DFEDTARU, correspondente ao limite superior.

Como a análise deste trabalho é organizada de acordo com os períodos delimitados pelos comunicados das reuniões do FOMC, foram mantidas apenas as observações da taxa de juros cujas datas coincidiam com as datas de publicação dos comunicados *Federal Reserve issues FOMC statement*. Dessa forma, a série diária original foi reduzida às observações correspondentes às decisões de política monetária utilizadas como referência na análise.

Para representar a mudança na política de juros entre reuniões consecutivas, foi utilizado o limite superior da faixa-alvo. Para uma reunião ocorrida na data t , a variação foi calculada pela diferença entre o limite superior observado nessa data e o limite superior correspondente à reunião anterior:

$$\Delta r_t = r_t^U - r_{t-1}^U,$$

em que r_t^U representa o limite superior da faixa-alvo da Federal Funds Rate na data t e r_{t-1}^U representa o limite superior observado na reunião anterior.

Assim, valores positivos de Δr_t representam elevação do limite superior da faixa-alvo entre duas reuniões consecutivas, valores negativos representam redução e valores iguais a zero indicam manutenção. Para a primeira observação da série, para a qual não existe uma reunião anterior disponível para o cálculo da diferença, o valor foi preenchido com zero.

A evolução da variação do limite superior da faixa-alvo ao longo das reuniões do FOMC é apresentada na Figura 9. Os valores positivos indicam elevações da taxa, enquanto os valores negativos representam reduções entre reuniões consecutivas.




Figura 9. Variação do limite superior da faixa-alvo da Federal Funds Rate entre reuniões consecutivas do FOMC.

Fonte: Autoria própria.

3.8 Correlação entre os Indicadores e a Variação da *Federal Funds Rate*

Para avaliar a associação entre a orientação monetária identificada nas comunicações do Federal Reserve e a variação do limite superior da faixa-alvo da *Federal Funds Rate*, representada por Δr_t , foram calculados os coeficientes de correlação de Pearson e de Spearman. A correlação de Pearson mede a associação linear entre as variáveis, enquanto a correlação de Spearman avalia a relação monotônica a partir das posições relativas das observações. Foram considerados os indicadores construídos com limiar de similaridade variável e com limiar fixo de 0,72. Os resultados são apresentados na Tabela 4.

Todos os coeficientes apresentados são positivos. Esse resultado indica que valores mais elevados dos indicadores, associados a uma orientação relativamente mais *hawkish* nas comunicações, estiveram associados a variações maiores do limite superior da taxa. De forma análoga, valores mais baixos dos indicadores, associados a uma orientação relativamente mais *dovish*, estiveram associados a variações menores ou negativas da taxa.

Com limiar variável, as correlações de Pearson variaram entre 0,458 e 0,495, e as de Spearman entre 0,438 e 0,497. O maior valor de Pearson foi observado para o indicador baseado nas comunidades identificadas pelo algoritmo de Leiden (0,495), enquanto o maior

Tabela 4. Correlações entre os indicadores de orientação monetária e a variação do limite superior da *Federal Funds Rate*.

	Limiar variável		Limiar fixo	
	Pearson	Spearman	Pearson	Spearman
Betweenness	0,460	0,460	0,503	0,483
Grau	0,475	0,495	0,477	0,501
PageRank	0,477	0,495	0,480	0,497
Comunidades Leiden	0,495	0,468	0,451	0,436
Leiden + Betweenness	0,458	0,438	0,476	0,460
Leiden + Grau	0,486	0,477	0,448	0,451
Leiden + PageRank	0,486	0,473	0,449	0,440
Média simples	0,485	0,497	0,485	0,497

Fonte: Autoria própria.

valor de Spearman foi obtido pela média simples (0,497). Os indicadores Grau e PageRank também apresentaram valores elevados de Spearman, ambos iguais a 0,495.

Com limiar fixo de 0,72, os coeficientes de Pearson variaram entre 0,448 e 0,503, e os de Spearman entre 0,436 e 0,501. O maior valor de Pearson foi obtido pelo indicador ponderado pela centralidade de intermediação (*Betweenness*), com 0,503. Para Spearman, o maior coeficiente foi observado no indicador ponderado por Grau, com 0,501, seguido pelos indicadores de média simples e PageRank, ambos com 0,497.

A comparação entre as duas medidas mostra que os resultados permanecem positivos, mas a magnitude varia conforme o indicador e o critério de construção da rede. A proximidade entre os coeficientes de Pearson e Spearman para vários indicadores sugere que parte da associação observada também é monotônica, embora não permita concluir que a relação seja estritamente linear. A escolha entre limiar variável e fixo também não produziu uma alteração uniforme: o limiar fixo favoreceu, por exemplo, os indicadores *Betweenness* e *Leiden + Betweenness*, enquanto o limiar variável apresentou valores maiores para os indicadores baseados nas comunidades de Leiden.

Por fim, esses resultados devem ser interpretados como evidência de associação entre as variáveis. Nenhum dos coeficientes permite estabelecer causalidade e, isoladamente, as correlações não demonstram capacidade preditiva dos indicadores.

3.9 Avaliação da utilidade e da capacidade preditiva dos indicadores

A correlação apresentada na seção anterior indica a existência de associação positiva entre os indicadores de orientação monetária e a variação subsequente da faixa-alvo da *Federal Funds Rate*. Entretanto, a existência de correlação, isoladamente, não permite determinar se os indicadores apresentam utilidade para antecipar as decisões do FOMC ou se a incorporação da estrutura do grafo acrescenta informação em relação à média simples das classificações. Para investigar essas questões, foram realizadas três análises complementares: regressões com erros-padrão robustos, avaliação do valor incremental dos indicadores de grafo e validação temporal fora da amostra.

3.9.1 Relação dos indicadores com a decisão subsequente

Inicialmente, foram estimados modelos de regressão linear relacionando cada indicador calculado no período entre duas reuniões consecutivas do FOMC com a variação da taxa observada na reunião seguinte. Para um indicador I_t , o modelo pode ser representado por

$$\Delta r_{t+1} = \alpha + \beta I_t + \varepsilon_t,$$

em que Δr_{t+1} corresponde à variação do limite superior da faixa-alvo observada ao final do período. As regressões foram estimadas utilizando erros-padrão robustos à heterocedasticidade e à autocorrelação pelo procedimento HAC de Newey-West, considerando uma defasagem.

A mesma análise foi realizada para as redes construídas com limiar de similaridade variável e com limiar fixo de 0,72. Foram utilizadas 95 observações em cada configuração. Os principais resultados são apresentados na Tabela 5.

Tabela 5. Regressões entre os indicadores de orientação monetária e a variação da taxa na reunião subsequente do FOMC.

Indicador	Limiar variável		Limiar fixo	
	β	R^2	β	R^2
Betweenness	0,313	0,211	0,337	0,253
Grau	0,300	0,225	0,299	0,228
PageRank	0,313	0,228	0,314	0,231
Comunidades Leiden	0,385	0,245	0,372	0,204
Leiden + Betweenness	0,325	0,210	0,337	0,227
Leiden + Grau	0,339	0,236	0,318	0,200
Leiden + PageRank	0,348	0,236	0,342	0,202
Média simples	0,356	0,236	0,356	0,236

Fonte: Autoria própria.

Todos os coeficientes estimados foram positivos e estatisticamente diferentes de zero, com valores de p corrigidos pelo procedimento HAC inferiores ou iguais a 0,001. Esse resultado indica que valores mais elevados dos indicadores, associados a uma orientação mais *hawkish*, estão relacionados a variações posteriores mais elevadas da taxa de juros.

No cenário com limiar variável, o indicador baseado nas comunidades de Leiden apresentou o maior coeficiente estimado ($\beta = 0,385$) e também o maior coeficiente de determinação entre os modelos individuais ($R^2 = 0,245$). Na configuração com limiar fixo, o maior R^2 foi observado para o indicador baseado na centralidade de intermediação ($R^2 = 0,253$).

Como teste adicional, os mesmos indicadores foram relacionados à decisão observada na reunião que marca o início de cada período. Em todas as versões avaliadas, a associação com essa decisão anterior foi superior àquela observada para a reunião seguinte, tanto em magnitude do coeficiente quanto em poder explicativo. Portanto, embora os indicadores apresentem associação estatisticamente significativa com a decisão subsequente,

os resultados não indicam que sua relação seja mais forte com a decisão futura do que com a decisão já observada no início do período.

Esse comportamento sugere cautela ao interpretar os indicadores como instrumentos de antecipação. Parte da informação capturada ao longo de cada intervalo pode estar associada à continuidade da orientação monetária vigente e às comunicações produzidas após a reunião que inicia o período.

3.9.2 Valor incremental da estrutura do grafo

Uma segunda análise foi realizada para verificar se os indicadores derivados da estrutura do grafo acrescentam informação à média simples das classificações. Para isso, foram comparados dois modelos. O modelo de referência utilizou exclusivamente a média simples dos sinais:

$$M_0 : \Delta r_{t+1} = \alpha + \beta_1 I_t^{\text{média}} + \varepsilon_t,$$

enquanto o segundo modelo acrescentou um dos indicadores derivados do grafo:

$$M_1 : \Delta r_{t+1} = \alpha + \beta_1 I_t^{\text{média}} + \beta_2 I_t^{\text{grafo}} + \varepsilon_t.$$

O valor incremental foi avaliado considerando conjuntamente três critérios: aumento do R^2 ajustado, redução do RMSE fora da amostra e significância estatística do coeficiente associado ao indicador de grafo, utilizando novamente erros-padrão HAC de Newey-West.

Nenhum dos indicadores avaliados satisfaz simultaneamente os três critérios. Na configuração com limiar variável, os pequenos aumentos de R^2 ajustado observados para PageRank e Comunidades Leiden não foram acompanhados por redução do RMSE fora da amostra, e seus coeficientes adicionais não apresentaram significância estatística.

Na configuração com limiar fixo, o resultado mais próximo de evidenciar ganho incremental foi obtido pela centralidade de intermediação. A inclusão de Betweenness elevou o R^2 ajustado de 0,228 para 0,238 e reduziu o RMSE fora da amostra de 0,2522 para 0,2501. Entretanto, o coeficiente adicional apresentou $p = 0,103$, valor superior ao nível de significância de 5%. Assim, mesmo nesse caso, não foi possível identificar evidência estatística suficiente de ganho incremental em relação à média simples.

Esses resultados mostram que as medidas baseadas na estrutura do grafo modificam a ponderação dos sinais e, em alguns casos, apresentam resultados individuais ligeiramente superiores, mas a informação adicional produzida por essas medidas apresenta elevada sobreposição com aquela já contida na média simples das classificações.

3.9.3 Validação temporal fora da amostra

Por fim, foi realizada uma validação temporal fora da amostra utilizando uma janela expansiva. As primeiras 30 reuniões foram utilizadas para estimar o modelo inicial. Em seguida, a decisão da reunião subsequente foi prevista e incorporada ao conjunto de treinamento antes da estimação da previsão seguinte. Esse procedimento foi repetido sequencialmente, preservando a ordem temporal das observações.

A avaliação resultou em 65 previsões fora da amostra, compreendendo o período entre dezembro de 2018 e setembro de 2026. O desempenho foi avaliado pelo erro absoluto médio (MAE), pela raiz do erro quadrático médio (RMSE) e pela capacidade de identificar a direção da decisão. Para essa última medida, variações superiores a 0,125 ponto percentual foram classificadas como alta, variações inferiores a -0,125 ponto percentual como corte e os demais casos como manutenção.

Além dos indicadores de orientação monetária, foi utilizado como referência um modelo que prevê a decisão seguinte a partir da média histórica das variações da taxa observadas até aquele momento. Os resultados são apresentados na Tabela 6.

Tabela 6. Desempenho dos indicadores na validação temporal fora da amostra.

Modelo	Limiar variável			Limiar fixo		
	MAE	RMSE	Acurácia	MAE	RMSE	Acurácia
Média histórica	0,1721	0,2847	0,6308	0,1721	0,2847	0,6308
Média simples	0,1898	0,2522	0,4923	0,1898	0,2522	0,4923
Betweenness	0,1827	0,2550	0,5077	0,1854	0,2490	0,5077
Grau	0,1909	0,2534	0,4769	0,1911	0,2531	0,4923
PageRank	0,1900	0,2531	0,4769	0,1905	0,2526	0,4769
Comunidades Leiden	0,1899	0,2520	0,5077	0,1844	0,2572	0,5385
Leiden + Betweenness	0,1857	0,2559	0,4923	0,1820	0,2527	0,5231
Leiden + Grau	0,1889	0,2526	0,4769	0,1838	0,2570	0,5231
Leiden + PageRank	0,1889	0,2526	0,4923	0,1849	0,2573	0,5538

Fonte: Autoria própria.

Em termos de RMSE, todas as versões dos indicadores apresentaram valores inferiores ao modelo baseado na média histórica, cujo RMSE foi igual a 0,2847. Na abordagem com limiar variável, o menor RMSE foi obtido pelo indicador de Comunidades Leiden (0,2520), valor muito próximo ao observado para a média simples (0,2522). Na abordagem com limiar fixo, o melhor resultado foi obtido por Betweenness, com RMSE igual a 0,2490.

A redução do RMSE indica que os indicadores foram capazes de reduzir a influência dos maiores erros de previsão em relação ao modelo baseado apenas na média histórica. Entretanto, esse resultado não foi reproduzido nas demais métricas. O modelo de média histórica apresentou o menor MAE, igual a 0,1721, enquanto o menor valor entre os indicadores de grafo foi de 0,1820, obtido por Leiden + Betweenness na configuração com limiar fixo.

Resultado semelhante foi observado na identificação da direção das decisões. A média histórica apresentou acurácia de 63,08%, superior à de todas as versões dos indicadores. Entre os indicadores de grafo, o melhor resultado foi obtido por Leiden + PageRank com limiar fixo, com acurácia de 55,38%. No cenário com limiar variável, a maior acurácia foi de 50,77%, alcançada por Comunidades Leiden e Betweenness.

Os resultados da validação fora da amostra mostram, portanto, que a avaliação da utilidade dos indicadores depende da métrica considerada. Os indicadores apresentam vantagem em RMSE em relação ao modelo baseado na média histórica, indicando menor ocorrência de erros de grande magnitude. Por outro lado, não apresentaram vantagem em

MAE ou na identificação da direção das decisões.

Considerando conjuntamente as análises realizadas, os resultados fornecem evidência de que os indicadores de orientação monetária contêm informação relacionada às decisões subsequentes do FOMC. Essa evidência é sustentada pelas correlações positivas e pelos coeficientes estatisticamente significativos das regressões. Entretanto, não foi encontrada evidência robusta de que a incorporação da estrutura do grafo produza valor preditivo incremental em relação à média simples das classificações. Além disso, embora os indicadores reduzam o RMSE fora da amostra em comparação à média histórica das decisões, essa melhora não é observada de forma consistente nas demais métricas.

Dessa forma, os resultados sustentam a utilidade dos indicadores principalmente como instrumentos de síntese quantitativa da orientação presente nas comunicações do Federal Reserve e como medidas associadas à trajetória posterior da política monetária. Sua utilização como instrumento de previsão das decisões do FOMC, entretanto, deve ser interpretada com cautela, especialmente diante da ausência de ganho incremental robusto dos indicadores baseados em grafos.

4 Conclusão

In this work we used Phasellus vitae dui eget leo tristique accumsan nec quis purus. In ac dapibus risus. Curabitur feugiat massa in aliquet tincidunt. Morbi congue quis lorem vitae finibus. Vestibulum euismod nunc et est bibendum rutrum. Maecenas lorem enim, porttitor eu justo eget, lacinia rutrum massa. Quisque id commodo arcu.

Referências

- Barrat, A.; Barthélemy, M.; Pastor-Satorras, R.; Vespignani, A., 2004 The architecture of complex weighted networks. *Proceedings of the National Academy of Sciences* 101(11): 3747–3752.
- Blinder, A. S.; Ehrmann, M.; Fratzscher, M.; de Haan, J.; Jansen, D.-J., 2008 Central bank communication and monetary policy: A survey of theory and evidence. *Journal of Economic Literature* 46(4): 910–945.
- Brown, T.; Mann, B.; Ryder, N.; Subbiah, M.; Kaplan, J. D.; Dhariwal, P.; Neelakantan, A.; Shyam, P.; Sastry, G.; Askell, A.; others, 2020 Language models are few-shot learners. *Advances in neural information processing systems* 33: 1877–1901.
- Freeman, L. C., 1977 A set of measures of centrality based on betweenness. *Sociometry* 40(1): 35–41.
- Gentzkow, M.; Kelly, B.; Taddy, M., 2019 Text as data. *Journal of Economic Literature* 57(3): 535–574, American Economic Association 2014 Broadway, Suite 305, Nashville, TN 37203-2425.
- Gil, A. C., 2010 Como elaborar projetos de pesquisa. Atlas, São Paulo, SP, Brasil, fifth edition.
- Gürkaynak, R. S.; Sack, B.; Swanson, E. T., 2005 Do actions speak louder than words? the response of asset prices to monetary policy actions and statements. *International Journal of Central Banking* 1(1): 55–93.
- Hansen, A. L.; Kazinnik, S., 2024 Can chatgpt decipher fedspeak? SSRN Working Paper No. 4399406.
- Loughran, T.; McDonald, B., 2011 When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of finance* 66(1): 35–65, Wiley Online Library.
- Needham, M.; Hodler, A. E., 2019 Graph algorithms: practical examples in Apache Spark and Neo4j. O'Reilly Media.
- Page, L.; Brin, S.; Motwani, R.; Winograd, T., 1999 The pagerank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab.
- Silva, T. C.; Moriya, K.; Veyrune, R. M., 2025 From text to quantified insights: A large-scale llm analysis of central bank communication. IMF Working Paper 2025/109, International Monetary Fund.
- Traag, V. A.; Waltman, L.; van Eck, N. J., 2019 From louvain to leiden: Guaranteeing well-connected communities. *Scientific Reports* 9(1): 5233.
- Woodford, M., 2005 Central bank communication and policy effectiveness. Technical Report 11898, National Bureau of Economic Research.

Apêndices

Apêndice I - Prompt utilizado na extração dos sinais monetários

<persona>

You are an economist specialized in analyzing central bank communications and
↪ monetary policy signals.

</persona>

<context>

Federal Reserve publication.

Title:

{title}

Publication date:

{publication_date}

Text:

{text}

</context>

<task>

Extract monetary policy signals from the publication and classify each signal
↪ according to the monetary policy stance it implies.

- dovish: Clearly supports monetary easing or maintaining an accommodative stance.

↪ Use when the signal indicates that inflation is at target, below target, or

↪ moving sustainably toward target; economic activity is weakening; or labor

↪ market conditions are softening in a way that reduces the need for restrictive

↪ policy.

- mostly_dovish: Leans toward monetary easing or delaying further tightening, but

↪ it is not definitive. Use when the signal reports progress on inflation,

↪ slower growth, or softer labor market conditions, while also mentioning

↪ uncertainty.

- neutral: The signal does not clearly imply either easing or tightening. Use when

↪ it does not indicate a dominant direction for policy. Do not classify as

↪ neutral merely because it is factual or descriptive.

- mostly_hawkish: Leans toward monetary tightening or delaying easing, but it is

↪ not definitive. Use when the signal reports elevated inflation, upside

↪ inflation risks, resilient demand, or strong labor market conditions, while

↪ also mentioning uncertainty.

- hawkish: Clearly supports monetary tightening or maintaining a restrictive

↪ stance. Use when the signal indicates that inflation is above target,

↪ persistent, broad-based, or rising; economic activity remains strong; or labor

↪ market conditions remain tight in a way that justifies restrictive policy.

Return a JSON object with the following structure:

{


```
"dovish": [
  {
    "signal": "monetary policy signal",
    "justification": "brief explanation of why this signal is
↪ classified as dovish",
    "evidence": "short supporting excerpt from the text"
  }
],
"mostly_dovish": [
  {
    "signal": "monetary policy signal",
    "justification": "brief explanation of why this signal is
↪ classified as mostly_dovish",
    "evidence": "short supporting excerpt from the text"
  }
],
"neutral": [
  {
    "signal": "monetary policy signal",
    "justification": "brief explanation of why this signal is
↪ classified as neutral",
    "evidence": "short supporting excerpt from the text"
  }
],
"mostly_hawkish": [
  {
    "signal": "monetary policy signal",
    "justification": "brief explanation of why this signal is
↪ classified as mostly_hawkish",
    "evidence": "short supporting excerpt from the text"
  }
],
"hawkish": [
  {
    "signal": "monetary policy signal",
    "justification": "brief explanation of why this signal is
↪ classified as hawkish",
    "evidence": "short supporting excerpt from the text"
  }
]
}
</task>
<guidelines>
- Do not extract signals unrelated to monetary policy.
- Each signal should express one main idea.
- Evidence must be a short excerpt copied from the text.
- If a category has no relevant signals, return an empty list.
</guidelines>
```