
Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Anderson Tonello Bringhenti^{1*}; Juliano Schimiguel

¹ Mestre em Engenharia Mecânica pela Universidade Federal de Santa Catarina, Florianópolis, SC, Brasil.

² Doutorado em Ciências da Computação. Av. Pádua Dias, 11 – São Dimas; 13418-900, Piracicaba, SP, Brasil

Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Resumo

O trabalho tem como objetivo investigar a aplicação conjunta de modelos de Large Language Models (LLMs) e grafos na análise de comunicações do Federal Reserve, com foco na identificação de sinais relacionados à orientação da política monetária. Foi utilizado como fontes documentos oficiais do Federal Reserve, por exemplo comunicados do FOMC, atas de reuniões, discursos, testemunhos e comunicados à imprensa. Inicialmente, foram coletados mais 1.200 links de comunicações públicas a partir do site oficial do FED, seguidos pela extração e preparação dos textos em formato estruturado. Em seguida, modelos de linguagem generativos foram utilizados para extrair sinais monetários e classificá-los em categorias de postura monetária, variando de dovish à hawkish. A partir dessa classificação cada sinal foi associado à uma pontuação numérica e um vetor de embedding, permitindo o cálculo de similaridade semântica usando similaridade de cosseno entre os vetores. A partir dessas informações, foi construída um grafo , composto por publicações, datas, sinais monetários e relações semânticas entre sinais. Os resultados

Palavras-chave: Federal Reserve; política monetária; modelos de linguagem; grafos; processamento de linguagem natural.

1 Introdução

A comunicação dos bancos centrais desempenha papel fundamental na formação das expectativas dos agentes econômicos e constitui parte relevante da própria transmissão da política monetária, uma vez que informações sobre perspectivas econômicas e possíveis trajetórias futuras dos juros podem influenciar as expectativas dos participantes do mercado (Woodford, 2005). No caso do Federal Reserve (Fed), autoridade monetária dos Estados Unidos, essa comunicação ocorre por meio de diferentes documentos, como comunicados e atas das reuniões do Federal Open Market Committee (FOMC), discursos de seus dirigentes e outros materiais institucionais. Essas divulgações são amplamente acompanhadas por participantes do mercado financeiro e pesquisadores, que buscam identificar sinais sobre a orientação futura da política monetária e antecipar possíveis decisões relacionadas à taxa básica de juros (Blinder *et al.*, 2008). Evidências empíricas indicam que os mercados reagem não apenas às decisões correntes sobre a taxa de juros, mas também às informações contidas nos comunicados do FOMC acerca da trajetória futura da política monetária (Gurkaynak *et al.*, 2005).

Apesar da relevância dessas comunicações, a interpretação de seu conteúdo ainda representa um desafio significativo. O volume elevado de documentos, aliado à complexidade da linguagem utilizada, dificulta a extração sistemática de informações e a identificação de padrões consistentes ao longo do tempo. Estudos indicam que análises tradicionais baseadas em leitura manual ou métodos simplificados apresentam limitações na captura de nuances semânticas e relações implícitas nos textos (Loughran e McDonald, 2011). Dessa forma, surge a problemática de como analisar, de maneira estruturada e automatizada, os conteúdos textuais produzidos pelo Federal Reserve, de modo a gerar insights úteis para a compreensão e antecipação da política monetária.

Essa problemática insere-se em um contexto onde documentos textuais são tratados como fontes de informação quantitativa para a investigação de fenômenos econômicos (Gentzkow *et al.*, 2019). Nesse contexto, os avanços recentes em técnicas de processamento de linguagem natural (Natural Language Processing - NLP), especialmente os chamados modelos de linguagem de grande porte (Large Language Models - LLMs), ampliaram significativamente as possibilidades de análise automatizada de textos complexos. Esses modelos são capazes de identificar padrões semânticos, extrair informações e sintetizar conteúdos presentes em grandes volumes de documentos textuais (Brown *et al.*, 2020).

De forma mais específica Hansen e Kazinnik (2024) investiga a capacidade de modelos GPT em interpretar a linguagem técnica utilizada pelo Federal Reserve em suas comunicações de política monetária. Os autores avaliam o desempenho desses modelos na classificação da orientação de comunicados do FOMC em comparação com avaliações humanas, indicando que os modelos GPT apresentam melhora relevante em relação a métodos tradicionais de classificação textual. Esse resultado reforça o potencial dos LLMs para capturar nuances semânticas presentes na comunicação de bancos centrais, especialmente na identificação de sinais associados a posturas mais expansionistas ou restritivas de política monetária.

Silva *et al.* (2025) utilizam modelos de linguagem de grande porte para analisar

comunicações de diferentes bancos centrais, classificando os documentos segundo dimensões como tópico, orientação da política monetária e sentimento. A partir dessas classificações, os autores constroem medidas quantitativas capazes de sintetizar a orientação presente nas comunicações e investigam sua relação com mudanças futuras na política monetária. Os resultados demonstram o potencial dos LLMs não apenas para interpretar grandes volumes de documentos textuais, mas também para transformar informações qualitativas presentes na comunicação dos bancos centrais em indicadores quantitativos passíveis de análise ao longo do tempo.

Paralelamente, técnicas baseadas em grafos permitem representar e analisar relações entre informações que não são facilmente observadas quando os elementos são considerados de forma isolada. Em uma rede, os nós representam os elementos de interesse e as conexões descrevem as relações existentes entre eles, possibilitando a investigação de propriedades como proximidade, centralidade e formação de comunidades (Needham e Hodler, 2019).

No contexto deste estudo, os sinais de política monetária identificados nas comunicações do Federal Reserve são representados em uma estrutura de grafo a partir de suas relações de similaridade semântica. Essa representação permite investigar não apenas a orientação individual de cada sinal, mas também sua posição relativa na rede, sua associação com outros sinais semanticamente semelhantes e a formação de agrupamentos que podem refletir padrões recorrentes na comunicação da autoridade monetária.

Paralelamente, técnicas de análise de grafos permitem representar e explorar relações entre informações extraídas de documentos. Algoritmos de grafos podem identificar proximidades e agrupamentos, revelando padrões difíceis de observar quando os dados são analisados isoladamente (Needham e Hodler, 2019). No contexto deste estudo, relações de similaridade semântica entre os sinais monetários extraídos das comunicações do Federal Reserve são utilizadas para construir uma rede sobre a qual podem ser analisadas estruturas de comunidades e medidas de centralidade. Essas propriedades estruturais servem para complementar a classificação atribuída individualmente aos sinais, uma vez que consideram também o contexto relacional em que cada sinal está inserido.

Embora estudos recentes tenham demonstrado o potencial dos modelos de linguagem para interpretar e quantificar a comunicação de bancos centrais, permanece menos explorada a utilização conjunta dessas técnicas com métodos de análise de grafos para investigar as relações existentes entre os sinais monetários extraídos dos documentos. Dessa forma, este estudo busca investigar se a combinação entre modelos de linguagem de grande porte e técnicas de análise de grafos pode contribuir para a construção de um indicador experimental da orientação da política monetária do Federal Reserve, avaliando sua capacidade de sintetizar padrões presentes nas comunicações e sua relação com decisões posteriores do FOMC.

2 Metodologia ou Material e Métodos

Este estudo possui uma abordagem qualitativa e quantitativa, e objetivo exploratório, uma vez que busca investigar a viabilidade de uma abordagem metodológica. De acordo

com Gil (2010), pesquisas exploratórias têm como finalidade obter maiores informações sobre o assunto que se pretende estudar, de maneira a proporcionar uma melhor delimitação do tema pesquisado, tornando-o mais explícito ou permitindo a construção de hipóteses. Nesse sentido, o objetivo metodológico não é estimar um modelo preditivo definitivo, mas avaliar a viabilidade de um procedimento para transformar comunicações de política monetária em sinais estruturados e comparáveis ao longo do tempo.

2.1 Coleta dos documentos

O conjunto textual utilizado é composto por documentos oficiais publicados pelo Federal Reserve, incluindo comunicados das reuniões do Federal Open Market Committee (FOMC), atas, discursos de dirigentes, testemunhos e comunicados de imprensa. Os documentos foram coletados a partir do site oficial da instituição. Para cada publicação, foram armazenadas informações de identificação, como o endereço eletrônico, a data e o texto, permitindo relacionar os sinais extraídos ao documento de origem e ao período correspondente.

2.2 Extração e classificação dos sinais

Após a coleta dos documentos, modelos de linguagem de grande porte (LLMs) foram utilizados para identificar sinais relacionados à política monetária e organizar as informações extraídas. Cada sinal recebeu uma classificação de postura monetária, podendo ser hawkish, mostly hawkish, neutral, mostly dovish ou dovish, além de uma pontuação numérica, uma justificativa e o trecho de evidência correspondente.

2.3 Representação vetorial e construção da rede

Para representar o conteúdo semântico dos sinais, cada um foi associado a um vetor de embedding. A partir desses vetores, foi calculada a similaridade do cosseno entre os sinais. O algoritmo k-nearest neighbors (KNN) foi então aplicado para selecionar, para cada sinal, os vizinhos semanticamente mais próximos, respeitando um número máximo de vizinhos e um limiar mínimo de similaridade.

O resultado é uma rede de similaridade semântica ponderada e não direcionada. Seus nós representam sinais monetários, enquanto suas arestas representam relações `SIMILAR_TO`; o peso de cada aresta corresponde ao escore de similaridade calculado entre os respectivos vetores. A rede permite identificar proximidades entre sinais que podem ter sido extraídos de documentos ou datas diferentes, mesmo quando essa relação não está explicitamente indicada no texto original. As informações de publicação, data, classificação, pontuação e evidência são mantidas como atributos dos sinais, permitindo análises posteriores por período.

2.4 Análise da rede - REFINAR

Após a construção da rede, foram aplicados algoritmos de análise de grafos para investigar sua organização estrutural. O algoritmo de Louvain foi utilizado para detectar

comunidades, isto é, agrupamentos de sinais que apresentam maior proximidade entre si. A modularidade foi considerada na avaliação da separação entre essas comunidades e o tamanho dos agrupamentos foi utilizado para caracterizar sua representatividade na rede.

O PageRank foi empregado como medida de centralidade. Diferentemente de uma simples contagem de conexões, essa métrica considera também a importância dos nós vizinhos, permitindo destacar sinais que ocupam posições relevantes na estrutura da rede. As medidas de centralidade, os agrupamentos identificados e as classificações de postura monetária foram combinados para produzir um indicador experimental da orientação presente nas comunicações analisadas.

2.5 Comparação temporal e avaliação - REFINAR

Por fim, o indicador foi organizado por período e comparado com as decisões observadas do FOMC, especialmente com a direção dos movimentos da taxa de juros. A avaliação foi realizada por meio da comparação temporal entre a trajetória do indicador e as decisões efetivamente tomadas, buscando verificar se os sinais extraídos e sua organização na rede acompanham mudanças na orientação da política monetária e se apresentam indícios de antecipação dessas mudanças.

Considerando o caráter exploratório da pesquisa, os resultados devem ser interpretados como evidência inicial sobre a utilidade da abordagem. A análise privilegia a coerência entre os sinais, a estrutura da rede e os eventos observados, sem pressupor, nesta etapa, a obtenção de elevado poder preditivo.

3 Resultados

Nesta seção são apresentados os resultados obtidos nas principais etapas do estudo: coleta das comunicações públicas do Federal Reserve, preparação dos textos, extração e classificação dos sinais de política monetária por modelos de linguagem e construção da rede de similaridade semântica.

Além de descrever o conjunto de dados e os sinais identificados, são analisadas as propriedades da rede construída, incluindo a distribuição das conexões, a formação de comunidades e a relevância estrutural dos nós. Por fim, os resultados são organizados temporalmente para avaliar a relação entre a orientação dos sinais extraídos e as decisões observadas do Federal Open Market Committee (FOMC).

3.1 Coleta dos links das publicações

Na etapa inicial da pesquisa, foram coletados, usando Python, os links referentes às comunicações públicas disponibilizadas pelo Federal Reserve em seu site oficial. O objetivo foi estruturar uma base documental para as etapas posteriores de extração textual, classificação dos sinais de política monetária e construção da rede de similaridade semântica entre os sinais extraídos.

Foram consideradas páginas relacionadas aos materiais de política monetária, ao calendário do Federal Open Market Committee (FOMC) e às comunicações públicas de dirigentes, como discursos e testemunhos. As principais fontes utilizadas são apresentadas na Tabela 1. A coleta contemplou comunicações publicadas entre janeiro de 2015 e 12 de setembro de 2025, permitindo a construção de uma base com abrangência temporal suficiente para a análise da evolução da comunicação monetária ao longo do período recente.

Tabela 1. Páginas do Federal Reserve utilizadas como fontes iniciais para a coleta.

Fonte consultada	Endereço eletrônico
Materiais de política monetária	https://www.federalreserve.gov/monetarypolicy/materials/
Calendário do FOMC	https://www.federalreserve.gov/monetarypolicy/fomccalendars.htm
Discursos e testemunhos	https://www.federalreserve.gov/newsevents/speeches-testimony.htm

Fonte: Autoria própria.

O procedimento de coleta combinou ferramentas distintas de acordo com a estrutura de cada página. Para os materiais de política monetária e para as páginas de discursos e testemunhos, que houve necessidade de navegação paginada, foi utilizado a biblioteca Selenium com o navegador Microsoft Edge. Essa ferramenta permitiu carregar as páginas, avançar entre os resultados e identificar os elementos HTML que continham os links das publicações. Já no calendário do FOMC, foram realizadas requisições HTTP com a biblioteca Requests, seguidas da análise do código HTML com BeautifulSoup. A partir dessa página, foram selecionados links para atas, comunicados de decisões monetárias, conferências de imprensa e tabelas de projeções.

Ao final da coleta, realizada até 12 de setembro de 2025, a base reuniu 1.306 links de publicações oficiais.

3.2 Extração e preparação dos textos

Após a obtenção dos links, iniciou-se a etapa de extração e preparação dos textos. Os resultados dessa etapa foram armazenados no arquivo JSON, que reúne, para cada publicação processada, a URL, o título, a data de publicação e o conteúdo textual. Antes do processamento de um novo endereço, a lista de URLs já armazenadas era carregada para evitar a repetição de documentos previamente extraídos.

Para as publicações disponibilizadas em páginas HTML, foram realizadas requisições HTTP com a biblioteca Requests. O conteúdo retornado foi interpretado com BeautifulSoup, e elementos sem conteúdo relevante para a análise, como scripts, estilos, menus, cabeçalhos, rodapés e elementos de navegação, foram removidos. Em seguida, o texto foi obtido a partir do conteúdo restante, com a eliminação de linhas vazias e de espaços excedentes. Esse procedimento produziu uma versão textual mais adequada às etapas posteriores de classificação e extração dos sinais monetários.

Além do conteúdo textual, foram identificados o título e a data de publicação de cada documento. Essas informações foram estruturadas no formato JSON com auxílio de

um modelo de linguagem, que recebeu como entrada o texto limpo da página e retornou os metadados no formato padronizado. A URL original foi mantida junto aos metadados para preservar a rastreabilidade das informações extraídas.

Algumas publicações, especialmente comunicados de imprensa e páginas do FOMC, disponibilizam seu conteúdo principal em arquivos PDF. Para esses casos, foram realizadas requisições HTTP às páginas associadas, cujo conteúdo HTML foi interpretado com BeautifulSoup. Inicialmente, eram localizadas todas as tags de hiperlink a, cujos atributos href eram avaliados para identificar links que continham a extensão .pdf. Quando os links estavam em formato relativo, eles eram corrigidos a partir da URL raiz do site. Em seguida, eram selecionados os arquivos relacionados ao comunicado ou às metas de longo prazo. O conteúdo dos PDFs foi extraído com a biblioteca PyPDF2, mediante leitura sequencial das páginas.

Durante a preparação, os documentos cujo título continha a expressão *implementation note* foram marcados como não extraídos, em vez de terem seu conteúdo utilizado nas etapas seguintes. Ao final de cada processamento, o registro era acrescentado ao arquivo JSON, que era atualizado incrementalmente. Esse procedimento permitiu preservar os dados já coletados e retomar a execução sem duplicar publicações.

Como resultado da etapa de extração, cada comunicação passou a ser representada em uma estrutura padronizada, contendo quatro campos principais: url, title, text e publication_date, conforme ilustrado na Figura 1.

```
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128a.htm",
  "title": "Federal Reserve issues FOMC statement",
  "text": "Available indicators suggest that economic activity has been expanding at a solid pace. Job gains have remained lo",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/monetarypolicy/fomcpressconf20260128.htm",
  "title": "January 27-28, 2026 FOMC Meeting",
  "text": "January 28, 2026 Chair Powell 's Press Conference FINAL \n \nPage 1 of 24 \n Transcript of Chair Powell 's P",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128b.htm",
  "title": "Federal Open Market Committee reaffirms its \"Statement on Longer-Run Goals and Monetary Policy Strategy\"",
  "text": "1 \n \nStatement on Longer -Run Goals and \nMonetary Policy Strategy \nAdopted effective January 24, 2012; as rea",
  "publication_date": "2026-01-28"
},
}
```

Figura 1. Exemplo da estrutura JSON produzida na etapa de extração dos textos.

Fonte: Autoria própria.

3.3 Extração e classificação dos sinais monetários

Após a estruturação da base textual, foi implementada a etapa de extração e classificação dos sinais de política monetária presentes nas comunicações do Federal Reserve. Essa etapa foi realizada por meio de um prompt estruturado, utilizado como entrada para o modelo de linguagem gpt-5.6-terra.

O prompt recebeu, para cada documento, três informações principais: título, data de publicação e texto integral da comunicação. A tarefa consistiu em identificar trechos que expressassem sinais relevantes para a condução da política monetária e classificá-los como

dovish, mostly dovish, neutral, mostly hawkish ou *hawkish*. Para reduzir ambiguidades, cada classe foi definida a partir de critérios relacionados ao comportamento da inflação, da atividade econômica, do mercado de trabalho e da orientação esperada da política monetária, conforme apresentado na Tabela 2.

Tabela 2. Descrição das classes para classificação dos sinais monetários.

Classe	Descrição
<i>dovish</i>	Clearly supports monetary easing or maintaining an accommodative stance. Use when the signal indicates that inflation is at target, below target, or moving sustainably toward target; economic activity is weakening; or labor market conditions are softening in a way that reduces the need for restrictive policy.
<i>mostly dovish</i>	Leans toward monetary easing or delaying further tightening, but it is not definitive. Use when the signal reports progress on inflation, slower growth, or softer labor market conditions, while also mentioning uncertainty.
<i>neutral</i>	The signal does not clearly imply either easing or tightening. Use when it does not indicate a dominant direction for policy. Do not classify as neutral merely because it is factual or descriptive.
<i>mostly hawkish</i>	Leans toward monetary tightening or delaying easing, but it is not definitive. Use when the signal reports elevated inflation, upside inflation risks, resilient demand, or strong labor market conditions, while also mentioning uncertainty.
<i>hawkish</i>	Clearly supports monetary tightening or maintaining a restrictive stance. Use when the signal indicates that inflation is above target, persistent, broad-based, or rising; economic activity remains strong; or labor market conditions remain tight in a way that justifies restrictive policy.

Fonte: Autoria própria.

A saída esperada do modelo foi definida em formato JSON, contendo, para cada categoria, uma lista de sinais extraídos. Cada sinal foi estruturado nos seguintes campos principais:

- **Signal:** ideia principal identificada;
- **Justification:** breve explicação para a classificação atribuída;
- **Evidence:** trecho curto extraído diretamente do texto original.

Essa estrutura aumenta a rastreabilidade das classificações e permite a transformação posterior dos resultados em uma base tabular.

Além da classificação textual, foi gerado um vetor de *embedding* para cada sinal extraído, utilizando o conteúdo do campo `signal`. Os vetores foram gerados pelo modelo `text-embedding-3-large`, com dimensão de 3.072 componentes. Cada vetor foi armazenado no campo `embedding_signal` e será utilizado para o cálculo da similaridade semântica entre os sinais monetários.

A tabela final contém as colunas `url`, `title`, `publication_date`, `classification`, `score`, `signal`, `justification`, `evidence` e `embedding_signal`. A coluna `score` contém

uma pontuação numérica associada à classificação, de acordo com o mapa apresentado na Tabela 3.

Tabela 3. Mapa da classificação para o escore.

Classificação	Escore
<i>dovish</i>	-1
<i>mostly_dovish</i>	-0,5
<i>neutral</i>	0
<i>mostly_hawkish</i>	0,5
<i>hawkish</i>	1

Fonte: Autoria própria.

3.4 Construção do grafo

Após a estruturação dos sinais monetários, os dados foram inseridos em um banco de dados orientado a grafos, Neo4j. A modelagem adotada contém dois tipos de nós: *Publication*, que representa cada comunicação do Federal Reserve, e *Signal*, que representa cada sinal monetário extraído. Os nós de publicação foram identificados pela URL do documento e armazenaram os atributos de título e data de publicação. Os nós de sinal foram identificados pela combinação entre o texto do sinal e a URL do documento de origem, permitindo distinguir sinais com conteúdo semelhante extraídos de publicações diferentes.

Cada nó *Signal* recebeu os atributos *classification*, *score*, *embedding_signal* e *date*. A relação *HAS_SIGNAL* foi criada entre cada nó *Publication* e os respectivos nós *Signal*, preservando a vinculação entre o sinal, sua evidência e a comunicação que o originou.

Além da relação *HAS_SIGNAL*, foram criadas relações *SIMILAR_TO* entre pares de nós *Signal* semanticamente semelhantes. Essa relação conecta sinais que apresentam proximidade de conteúdo, independentemente de terem sido extraídos da mesma publicação ou de documentos distintos. Por ser não direcionada, a relação representa uma associação mútua entre os sinais, e seu atributo *score_similarity* registra a intensidade da similaridade calculada entre os respectivos vetores de *embedding*. A definição dos períodos, o cálculo da similaridade e os critérios utilizados para selecionar essas conexões são apresentados na seção seguinte.

Essa estrutura é ilustrada na Figura 2.

3.5 Conexões *SIMILAR_TO*

As conexões *SIMILAR_TO* não foram criadas considerando todos os nós *Signal* existentes no grafo. Para evitar comparações entre sinais pertencentes a períodos distintos, as conexões foram construídas separadamente dentro de cada período de análise, utilizando apenas os nós selecionados para esse intervalo.

Para definir esses períodos, foram utilizadas as datas dos comunicados do FOMC, obtidas a partir da base textual estruturada na etapa de extração. Foram selecionados os registros cujo título correspondia a *Federal Reserve issues FOMC statement*, referentes aos comunicados oficiais divulgados após as reuniões do comitê. As datas de publicação



Figura 2. Esquema dos nós e das relações utilizados na construção do grafo.
Fonte: Autoria própria.

desses registros foram reunidas em um conjunto, com a eliminação de eventuais repetições, e posteriormente ordenadas cronologicamente.

Cada período foi delimitado por duas datas consecutivas dessa sequência. Em cada intervalo, foram selecionados apenas os nós *Signal* que possuíam vetor de *embedding* e cuja data de publicação estivesse compreendida entre o início do período, inclusive, e a data do comunicado subsequente, exclusive. Em cada período, foram considerados os sinais publicados entre duas datas consecutivas do FOMC, incluindo a data inicial e excluindo a data final. Portanto, embora as comunicações divulgadas na data inicial integrem o período, todas as comunicações publicadas na data de divulgação do *statement* que encerra o intervalo são excluídas da construção do indicador desse período. Essa regra evita que o indicador incorpore informações divulgadas juntamente com a decisão do FOMC que ele busca avaliar e preserva seu caráter prospectivo.

Os nós selecionados foram projetados no Neo4j Graph Data Science (GDS), isto é, foram organizados em uma representação temporária em memória contendo somente os nós do período e a propriedade vetorial *embedding_signal*. Essa projeção é independente do grafo armazenado permanentemente no banco de dados e serve como estrutura de entrada para a execução dos algoritmos do GDS. Sobre ela, foi aplicado o algoritmo *k*-nearest neighbors (KNN), utilizando a similaridade do cosseno para comparar os vetores. Para cada sinal, foram considerados até 50 vizinhos semanticamente mais próximos, o que restringe a rede às relações mais relevantes e evita a formação de um grafo excessivamente denso.

No Neo4j GDS, o procedimento `gds.knn.stream` opera sobre a projeção em memória e retorna, para cada comparação selecionada, os identificadores dos dois nós e o respectivo escore de similaridade. Esses identificadores foram então convertidos novamente em nós *Signal* e os pares duplicados foram eliminados antes de sua persistência no banco.

Foram mantidos somente os pares cuja similaridade excedesse um limiar mínimo. O procedimento foi iniciado com limiar de 0,80 e, quando a rede resultante ainda apresentava mais de uma componente conexa, o valor foi reduzido em incrementos de 0,01 até o mínimo de 0,10. A cada iteração, a conectividade foi verificada por meio do algoritmo de componentes fracamente conectadas. O limiar selecionado para cada período foi, portanto, o maior valor

que produziu uma única componente conexa dentro dos limites definidos pelo procedimento.

Os pares identificados foram armazenados como relações `SIMILAR_TO` não direcionadas. Cada relação recebeu o atributo `score_similarity`, que corresponde ao valor da similaridade do cosseno entre os respectivos sinais. Assim, cada período é representado por uma rede ponderada, na qual os nós são sinais monetários e as arestas expressam a intensidade de sua proximidade semântica, inclusive quando os sinais são provenientes de documentos distintos.

Teste wq a

4 Conclusão

In this work we used Phasellus vitae dui eget leo tristique accumsan nec quis purus. In ac dapibus risus. Curabitur feugiat massa in aliquet tincidunt. Morbi congue quis lorem vitae finibus. Vestibulum euismod nunc et est bibendum rutrum. Maecenas lorem enim, porttitor eu justo eget, lacinia rutrum massa. Quisque id commodo arcu.

Referências

- Blinder, A. S.; Ehrmann, M.; Fratzscher, M.; De Haan, J.; Jansen, D., 2008 Central bank communication and monetary policy: A survey of theory and evidence. *Journal of Economic Literature* 46(4): 910–945, American Economic Association.
- Brown, T.; Mann, B.; Ryder, N.; Subbiah, M.; Kaplan, J. D.; Dhariwal, P.; Neelakantan, A.; Shyam, P.; Sastry, G.; Askell, A.; others, 2020 Language models are few-shot learners. *Advances in neural information processing systems* 33: 1877–1901.
- Gentzkow, M.; Kelly, B.; Taddy, M., 2019 Text as data. *Journal of Economic Literature* 57(3): 535–574, American Economic Association 2014 Broadway, Suite 305, Nashville, TN 37203-2425.
- Gil, A. C., 2010 Como elaborar projetos de pesquisa. Atlas, São Paulo, SP, Brasil, fifth edition.
- Gurkaynak, R. S.; Sack, B.; Swanson, E. T., 2005 Do actions speak louder than words? the response of asset prices to monetary policy actions and statements .
- Hansen, A. L.; Kazinnik, S., 2024 Can chatgpt decipher fedspeak? Disponível em SSRN 4399406 .
- Loughran, T.; McDonald, B., 2011 When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of finance* 66(1): 35–65, Wiley Online Library.
- Needham, M.; Hodler, A. E., 2019 Graph algorithms: practical examples in Apache Spark and Neo4j. O'Reilly Media.
- Silva, T. C.; Moriya, K.; Veyrune, M. R. M.; Veyrune, R., 2025 From text to quantified insights: A large-scale llm analysis of central bank communication. International Monetary Fund.

Woodford, M., 2005 Central bank communication and policy effectiveness. National Bureau of Economic Research Cambridge, Mass., USA.