
Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Anderson Tonello Bringhenti^{1*}; Juliano Schimiguel

¹ Mestre em Engenharia Mecânica pela Universidade Federal de Santa Catarina, Florianópolis, SC, Brasil.

² Doutorado em Ciências da Computação. Av. Pádua Dias, 11 – São Dimas; 13418-900, Piracicaba, SP, Brasil

Aplicação de Modelos de Large Language Models (LLMs) e grafos na Análise de Comunicações do Federal Reserve

Resumo

O trabalho tem como objetivo investigar a aplicação conjunta de modelos de Large Language Models (LLMs) e grafos na análise de comunicações do Federal Reserve, com foco na identificação de sinais relacionados à orientação da política monetária. Foi utilizado como fontes documentos oficiais do Federal Reserve, por exemplo comunicados do FOMC, atas de reuniões, discursos, testemunhos e comunicados à imprensa. Inicialmente, foram coletados mais 1.200 links de comunicações públicas a partir do site oficial do FED, seguidos pela extração e preparação dos textos em formato estruturado. Em seguida, modelos de linguagem generativos foram utilizados para extrair sinais monetários e classificá-los em categorias de postura monetária, variando de dovish à hawkish. A partir dessa classificação cada sinal foi associado à uma pontuação numérica e um vetor de embedding, permitindo o cálculo de similaridade semântica usando similaridade de cosseno entre os vetores. A partir dessas informações, foi construída um grafo, composto por publicações, datas, sinais monetários e relações semânticas entre sinais. Os resultados

Palavras-chave: Federal Reserve; política monetária; modelos de linguagem; grafos; processamento de linguagem natural.

1 Introdução

A comunicação dos bancos centrais desempenha papel fundamental na formação das expectativas dos agentes econômicos e na transmissão da política monetária, pois informações sobre as perspectivas econômicas e as trajetórias futuras dos juros podem influenciar as decisões dos participantes do mercado (Woodford, 2005). No caso do Federal Reserve (Fed), essa comunicação ocorre em documentos como comunicados e atas do Federal Open Market Committee (FOMC), discursos de seus dirigentes e outros materiais institucionais. Essas divulgações são acompanhadas por participantes do mercado e pesquisadores interessados em identificar sinais sobre a orientação futura da política monetária (Blinder *et al.*, 2008). Além das decisões correntes sobre a taxa de juros, os mercados também reagem às informações dos comunicados do FOMC sobre a trajetória futura da política monetária (Gürkaynak *et al.*, 2005).

A interpretação dessas comunicações, contudo, é dificultada pelo volume de documentos e pela complexidade de sua linguagem. Métodos baseados em dicionários genéricos podem ser limitados em documentos financeiros, pois o significado dos termos depende do contexto (Loughran e McDonald, 2011). Surge, assim, o desafio de analisar de forma estruturada e automatizada os conteúdos produzidos pelo Fed, gerando subsídios para a compreensão e antecipação da política monetária.

Esse desafio insere-se no uso de documentos textuais como fontes de informação quantitativa para a investigação de fenômenos econômicos (Gentzkow *et al.*, 2019). Avanços em processamento de linguagem natural (*Natural Language Processing* - NLP), especialmente os modelos de linguagem de grande porte (*Large Language Models* - LLMs), ampliaram a análise automatizada de textos complexos, permitindo realizar diferentes tarefas a partir de instruções e exemplos fornecidos em contexto (Brown *et al.*, 2020).

De forma específica, Hansen e Kazinnik (2024) avalia a capacidade de modelos GPT de interpretar a linguagem técnica do Fed e classificar a orientação de comunicados do FOMC. Em comparação com avaliações humanas e métodos tradicionais, os modelos apresentam desempenho superior, reforçando seu potencial para capturar nuances semânticas e identificar sinais de orientação expansionista ou restritiva.

De modo semelhante, Silva *et al.* (2025) utiliza LLMs para classificar comunicações de diferentes bancos centrais segundo tópico, orientação monetária e sentimento. A partir dessas classificações, os autores constroem medidas quantitativas e investigam sua relação com mudanças futuras na política monetária, demonstrando a possibilidade de transformar informações qualitativas em indicadores.

Paralelamente, técnicas de análise de grafos permitem representar relações que não são observadas quando os elementos são considerados isoladamente. Nessa estrutura, os nós representam os elementos de interesse e as conexões descrevem suas relações, possibilitando investigar proximidade, centralidade e comunidades (Needham e Hodler, 2019).

Neste estudo, os sinais de política monetária identificados nas comunicações do Fed são representados em um grafo com base em suas relações de similaridade semântica. Essa representação permite examinar a orientação de cada sinal, sua posição na rede, as associações entre sinais semelhantes e a formação de agrupamentos recorrentes. Para

isso, a análise avalia a conectividade da rede, identifica comunidades e calcula medidas de centralidade.

O algoritmo de componentes fracamente conectados (*weakly connected components* – WCC) identifica subconjuntos de nós que permanecem conectados quando a direção das relações é desconsiderada (Needham e Hodler, 2019). No presente estudo, o algoritmo é empregado para verificar a conectividade global da rede e orientar a definição do limiar de similaridade semântica, evitando que a análise subsequente seja realizada sobre grupos isolados de sinais.

Para identificar esses agrupamentos, emprega-se o algoritmo de Leiden, um método de detecção de comunidades que otimiza uma função de qualidade da partição e assegura que as comunidades obtidas sejam bem conectadas internamente. Essa propriedade permite separar conjuntos de sinais com maior similaridade semântica entre si, favorecendo a identificação de temas ou padrões recorrentes na comunicação monetária (Traag *et al.*, 2019).

A centralidade de intermediação (*betweenness centrality*) quantifica a frequência com que um nó se encontra nos caminhos geodésicos entre outros pares de nós. Na rede de sinais, essa medida destaca observações que podem conectar grupos semanticamente distintos e, portanto, ocupar uma posição de intermediação na estrutura relacional (Freeman, 1977).

A centralidade de grau ponderado mensura a intensidade das conexões de cada nó a partir dos pesos associados às suas arestas. Nesse caso, a força de um nó pode ser representada pela soma dos pesos de suas conexões, permitindo distinguir nós conectados por relações de maior intensidade (Barrat *et al.*, 2004). Neste estudo, essa medida permite atribuir maior relevância aos sinais associados a relações semanticamente mais fortes.

O PageRank estima a importância relativa de um nó ao considerar não somente suas conexões, mas também a importância dos nós aos quais ele está ligado (Page *et al.*, 1999). Aplicado à rede ponderada de similaridade, o algoritmo permite destacar sinais conectados a outros sinais estruturalmente relevantes, oferecendo uma ponderação relacional adicional para os indicadores de orientação monetária.

Embora estudos recentes demonstrem o potencial dos modelos de linguagem para interpretar e quantificar a comunicação de bancos centrais, permanece menos explorada sua utilização conjunta com métodos de análise de grafos para investigar as relações entre sinais monetários. Assim, este estudo avalia se essa combinação contribui para a construção de um indicador experimental da orientação da política monetária do Fed, examinando sua capacidade de sintetizar padrões das comunicações e sua relação com decisões posteriores do FOMC.

2 Material e Métodos

Este estudo possui uma abordagem qualitativa e quantitativa, e objetivo exploratório, uma vez que busca investigar a viabilidade de uma abordagem metodológica. De acordo com Gil (2010), pesquisas exploratórias têm como finalidade obter maiores informações sobre o assunto que se pretende estudar, de maneira a proporcionar uma melhor delimitação do tema pesquisado, tornando-o mais explícito ou permitindo a construção de hipóteses. Nesse sentido, o objetivo metodológico não é estimar um modelo preditivo definitivo, mas avaliar a viabilidade de um procedimento para transformar comunicações de política monetária em sinais estruturados e comparáveis ao longo do tempo.

2.1 Coleta dos documentos

O conjunto textual utilizado é composto por documentos oficiais publicados pelo FED, incluindo comunicados das reuniões do FOMC, atas, discursos de dirigentes, testemunhos e comunicados de imprensa. Os documentos foram coletados a partir do site oficial da instituição. Para cada publicação, foram armazenadas informações de identificação, como o endereço eletrônico, a data e o texto, permitindo relacionar os sinais extraídos ao documento de origem e ao período correspondente.

2.2 Extração e classificação dos sinais

Após a coleta dos documentos, modelos de linguagem de grande porte (LLMs) foram utilizados para identificar sinais relacionados à política monetária e organizar as informações extraídas. Cada sinal recebeu uma classificação de postura monetária, podendo ser *hawkish*, *mostly hawkish*, *neutral*, *mostly dovish* ou *dovish*, além de uma pontuação numérica, uma justificativa e o trecho de evidência correspondente.

2.3 Representação vetorial e construção da rede

Para representar o conteúdo semântico dos sinais, cada um foi associado a um vetor de *embedding*. A partir desses vetores, foi calculada a similaridade do cosseno entre os sinais. O algoritmo *k-nearest neighbors* (KNN) foi então aplicado para selecionar, para cada sinal, os vizinhos semanticamente mais próximos, respeitando um número máximo de vizinhos e um limiar mínimo de similaridade.

O resultado é uma rede de similaridade semântica ponderada e não direcionada. Seus nós representam sinais monetários, enquanto suas arestas representam relações *SIMILAR_TO*; o peso de cada aresta corresponde ao escore de similaridade calculado entre os respectivos vetores. A rede permite identificar proximidades entre sinais que podem ter sido extraídos de documentos ou datas diferentes, mesmo quando essa relação não está explicitamente indicada no texto original. As informações de publicação, data, classificação, pontuação e evidência são mantidas como atributos dos sinais, permitindo análises posteriores por período.

2.4 Análise da estrutura da rede de similaridade semântica

As análises foram realizadas separadamente para cada período de interesse. Antes da identificação das comunidades, foi aplicado o algoritmo de componentes fracamente conectados (*weakly connected components* – WCC) para avaliar a conectividade da rede. O limiar mínimo de similaridade foi reduzido em etapas sucessivas até que os sinais do período formassem uma única componente conexa. Esse procedimento buscou evitar que a análise fosse realizada sobre grupos isolados e definiu a rede utilizada nas etapas seguintes.

Sobre essa rede, o algoritmo de Leiden foi executado utilizando o escore de similaridade como peso das relações, permitindo identificar comunidades de sinais semanticamente próximos. Para caracterizar sua estrutura, foram registrados o número de comunidades, o tamanho da maior comunidade e a pontuação média dos sinais em cada grupo. A modularidade não foi utilizada como critério de seleção no procedimento implementado; a interpretação das comunidades baseou-se em sua composição, tamanho e orientação média.

A relevância estrutural dos sinais foi avaliada por três medidas ponderadas pelo escore de similaridade: centralidade de intermediação, centralidade de grau e PageRank. A primeira destaca nós situados nos caminhos entre diferentes regiões da rede; a segunda mensura a intensidade total de suas conexões; e o PageRank considera também a relevância dos nós vizinhos. Para cada medida, foi calculada uma média ponderada da pontuação de postura monetária dos sinais. Também foram obtidas a média simples das pontuações e medidas agregadas por comunidade, incluindo médias com pesos iguais e ponderadas pelo PageRank. Esses resultados compõem as versões do indicador experimental avaliadas na etapa de comparação temporal.

2.5 Comparação temporal e avaliação - REFINAR

Por fim, o indicador foi organizado por período e comparado com as decisões observadas do FOMC, especialmente com a direção dos movimentos da taxa de juros. A avaliação foi realizada por meio da comparação temporal entre a trajetória do indicador e as decisões efetivamente tomadas, buscando verificar se os sinais extraídos e sua organização na rede acompanham mudanças na orientação da política monetária e se apresentam indícios de antecipação dessas mudanças.

Considerando o caráter exploratório da pesquisa, os resultados devem ser interpretados como evidência inicial sobre a utilidade da abordagem. A análise privilegia a coerência entre os sinais, a estrutura da rede e os eventos observados, sem pressupor, nesta etapa, a obtenção de elevado poder preditivo.

3 Resultados

Nesta seção são apresentados os resultados obtidos nas principais etapas do estudo: coleta das comunicações públicas do Federal Reserve, preparação dos textos, extração e classificação dos sinais de política monetária por modelos de linguagem, construção da rede de similaridade semântica, definição do indicador e validação da sua capacidade de refletir a orientação da política monetária.

Além de descrever o conjunto de dados e os sinais identificados, são analisadas as propriedades da rede construída, incluindo a distribuição das conexões, a formação de comunidades e a relevância estrutural dos nós. Por fim, os resultados são organizados temporalmente para avaliar a relação entre a orientação dos sinais extraídos e as decisões observadas do Federal Open Market Committee (FOMC).

3.1 Coleta dos links das publicações

Na etapa inicial da pesquisa, foram coletados, usando Python, os links referentes às comunicações públicas disponibilizadas pelo Federal Reserve em seu site oficial. Ao todo, foram obtidos 1.310 links. O objetivo foi estruturar as origens da base documental à ser utilizada nas etapas de extração textual e classificação dos sinais de política monetária.

Foram consideradas páginas relacionadas aos materiais de política monetária, ao calendário do Federal Open Market Committee (FOMC) e às comunicações públicas de dirigentes, como discursos e testemunhos. Os endereços apresentados na Tabela 1 correspondem a páginas institucionais de consulta que reúnem links para os textos integrais das publicações, e não aos documentos individuais que compõem a base. Em particular, o Calendário do FOMC disponibiliza os links para as atas e os comunicados associados a cada reunião do Comitê. A partir dessas páginas, foram extraídos os links das comunicações publicadas entre janeiro de 2015 e setembro de 2025.

Tabela 1. Páginas do Federal Reserve utilizadas como fontes iniciais para a coleta.

Fonte consultada	Endereço eletrônico
Materiais de política monetária	https://www.federalreserve.gov/monetarypolicy/materials/
Calendário do FOMC	https://www.federalreserve.gov/monetarypolicy/fomccalendars.htm
Discursos e testemunhos	https://www.federalreserve.gov/newsevents/speeches-testimony.htm

Fonte: Autoria própria.

O procedimento de coleta dos links combinou ferramentas distintas de acordo com a estrutura de cada página. Para os materiais de política monetária e para as páginas de discursos e testemunhos, que houve necessidade de navegação paginada, foi utilizado a biblioteca Selenium com o navegador Microsoft Edge. Essa ferramenta permitiu carregar as páginas, avançar entre os resultados e identificar os elementos HTML que continham os links das publicações. Já no calendário do FOMC, foram realizadas requisições HTTP com a biblioteca Requests, seguidas da análise do código HTML com BeautifulSoup.

3.2 Extração e padronização dos textos

Após a obtenção dos endereços eletrônicos das publicações, foi realizada a etapa de extração e padronização de seu conteúdo textual. Os resultados foram armazenados em formato JSON, mantendo-se, para cada publicação processada, a URL de origem, o título, a data de publicação e o texto extraído. Antes do processamento de um novo endereço, eram verificadas as URLs já presentes no conjunto de dados, evitando o processamento repetido de publicações previamente extraídas.

Para as publicações disponibilizadas diretamente em páginas HTML, foram realizadas requisições HTTP por meio da biblioteca *Requests*. As requisições foram configuradas com tempo limite de resposta e, após o recebimento do conteúdo, sua codificação foi definida como UTF-8. O documento HTML retornado foi então interpretado utilizando a biblioteca *Beautiful Soup*.

Antes da obtenção do texto, foram removidos elementos HTML sem interesse para a análise, especificamente as tags `script`, `style`, `noscript`, `header`, `footer` e `nav`. Em seguida, o conteúdo restante da página foi convertido em texto, utilizando quebras de linha como separadores. Cada linha foi posteriormente tratada para remoção de espaços excedentes em suas extremidades, e as linhas vazias foram descartadas. O resultado desse procedimento constituiu o conteúdo textual utilizado nas etapas seguintes do trabalho.

A identificação do título e da data de publicação foi realizada com auxílio de um modelo de linguagem de grande escala. O texto obtido após o tratamento da página HTML foi fornecido ao modelo juntamente com uma instrução para retornar essas duas informações em formato JSON. A data de publicação foi padronizada no formato YYYY-MM-DD. Após o processamento, a URL original e o conteúdo textual previamente extraído eram incorporados ao registro, resultando em uma estrutura padronizada para cada publicação.

Para documentos cujo conteúdo estava disponibilizado em arquivos PDF, foi adotado um procedimento específico. Inicialmente, a página associada à publicação era obtida por meio de uma requisição HTTP e processada com *Beautiful Soup*. Todas as tags de hiperlink `<a>` eram examinadas e seus atributos `href` avaliados para identificar endereços contendo a extensão `.pdf`.

Após a identificação do arquivo, uma nova requisição HTTP era realizada para seu download. O documento era armazenado temporariamente como arquivo PDF e processado com a biblioteca *PyPDF2*. A extração era realizada sequencialmente, percorrendo todas as páginas do documento por meio da classe `PdfReader` e concatenando o conteúdo textual obtido. Após a conclusão da leitura, o arquivo temporário era removido.

Durante a preparação, os documentos cujo título continha a expressão *implementation note* foram marcados como não extraídos, em vez de terem seu conteúdo utilizado nas etapas seguintes. Ao final de cada processamento, o registro era acrescentado ao arquivo JSON, que era atualizado incrementalmente. Esse procedimento permitiu preservar os dados já coletados e retomar a execução sem duplicar publicações.

Como resultado da etapa de extração, cada comunicação passou a ser representada em uma estrutura padronizada, contendo quatro campos principais: `url`, `title`, `text` e `publication_date`, conforme ilustrado na Figura 1.

```
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128a.htm",
  "title": "Federal Reserve issues FOMC statement",
  "text": "Available indicators suggest that economic activity has been expanding at a solid pace. Job gains have remained lo",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/monetarypolicy/fomcpressconf20260128.htm",
  "title": "January 27-28, 2026 FOMC Meeting",
  "text": "January 28, 2026 Chair Powell 's Press Conference FINAL \n \nPage 1 of 24 \n Transcript of Chair Powell 's P",
  "publication_date": "2026-01-28"
},
{
  "url": "https://www.federalreserve.gov/newsevents/pressreleases/monetary20260128b.htm",
  "title": "Federal Open Market Committee reaffirms its \"Statement on Longer-Run Goals and Monetary Policy Strategy\"",
  "text": "1 \n \nStatement on Longer -Run Goals and \nMonetary Policy Strategy \nAdopted effective January 24, 2012; as rea",
  "publication_date": "2026-01-28"
},
}
```

Figura 1. Exemplo da estrutura JSON produzida na etapa de extração dos textos.
Fonte: Autoria própria.

3.3 Extração e classificação dos sinais monetários

Após a estruturação da base textual, foi realizada a etapa de identificação e classificação dos sinais de política monetária presentes nas comunicações do Federal Reserve. Para essa finalidade, foi utilizado um modelo de linguagem de grande porte, instruído por meio de um prompt estruturado a atuar como um economista especializado na análise de comunicações de bancos centrais e de sinais relacionados à política monetária.

Para cada documento, o prompt recebeu como contexto três informações provenientes da etapa anterior: o título da publicação, a data de publicação e o conteúdo textual da comunicação. A partir dessas informações, o modelo gpt-5.6-terra foi instruído a identificar somente sinais relacionados à política monetária e a classificar cada sinal de acordo com a orientação monetária implícita. A execução foi configurada para produzir respostas estruturadas em formato JSON, com temperatura igual a zero e sem esforço adicional de raciocínio.

Foram definidas cinco categorias de orientação monetária: *dovish*, *mostly dovish*, *neutral*, *mostly hawkish* e *hawkish*. As definições incorporadas ao prompt consideraram principalmente informações relacionadas à inflação, à atividade econômica, ao mercado de trabalho e à orientação esperada da política monetária. Os critérios utilizados são apresentados na Tabela 2.

Além das definições das classes, o prompt estabeleceu regras para tornar a extração mais consistente. Foram considerados apenas sinais relacionados à política monetária, e cada sinal deveria representar uma única ideia principal. Para cada classificação, o modelo deveria retornar uma lista de sinais identificados, sendo utilizada uma lista vazia quando nenhum sinal correspondente fosse encontrado no documento.

A saída esperada foi definida como um objeto JSON organizado pelas cinco categorias de classificação. Para cada sinal identificado, foram retornados três campos:

- *signal*: síntese da principal informação ou sinal de política monetária identificado;
- *justification*: breve justificativa para a classificação atribuída;

Tabela 2. Descrição das classes para classificação dos sinais monetários.

Classe	Descrição
<i>dovish</i>	Clearly supports monetary easing or maintaining an accommodative stance. Use when the signal indicates that inflation is at target, below target, or moving sustainably toward target; economic activity is weakening; or labor market conditions are softening in a way that reduces the need for restrictive policy.
<i>mostly dovish</i>	Leans toward monetary easing or delaying further tightening, but it is not definitive. Use when the signal reports progress on inflation, slower growth, or softer labor market conditions, while also mentioning uncertainty.
<i>neutral</i>	The signal does not clearly imply either easing or tightening. Use when it does not indicate a dominant direction for policy. Do not classify as neutral merely because it is factual or descriptive.
<i>mostly hawkish</i>	Leans toward monetary tightening or delaying easing, but it is not definitive. Use when the signal reports elevated inflation, upside inflation risks, resilient demand, or strong labor market conditions, while also mentioning uncertainty.
<i>hawkish</i>	Clearly supports monetary tightening or maintaining a restrictive stance. Use when the signal indicates that inflation is above target, persistent, broad-based, or rising; economic activity remains strong; or labor market conditions remain tight in a way that justifies restrictive policy.

Fonte: Autoria própria.

- *evidence*: trecho curto, reproduzido diretamente da comunicação original, utilizado como evidência para o sinal identificado.

Na próxima etapa, cada sinal foi convertido em um registro individual. A classificação textual foi então associada a um escore numérico por meio de um mapeamento determinístico, independente do modelo de linguagem. Os valores variam de -1 , correspondente à orientação mais *dovish*, a 1 , correspondente à orientação mais *hawkish*, conforme apresentado na Tabela 3.

Tabela 3. Mapa da classificação para o escore.

Classificação	Escore
<i>dovish</i>	-1
<i>mostly_dovish</i>	-0,5
<i>neutral</i>	0
<i>mostly_hawkish</i>	0,5
<i>hawkish</i>	1

Fonte: Autoria própria.

Além da classificação e do escore, foi gerada uma representação vetorial para cada sinal extraído. Para isso, somente o conteúdo do campo `signal` foi fornecido ao modelo de embeddings `text-embedding-3-large`. Cada sinal foi representado por um vetor com 3.072 componentes, armazenado no campo `embedding_signal`. Esses vetores

foram posteriormente utilizados para representar a proximidade semântica entre os sinais monetários e constituir as relações de similaridade empregadas na construção do grafo.

Ao final do processamento, cada sinal monetário passou a corresponder a uma linha da base tabular, contendo os campos `url`, `title`, `publication_date`, `classification`, `score`, `signal`, `justification`, `evidence` e `embedding_signal`. Os novos registros eram concatenados aos resultados já existentes e armazenados incrementalmente em arquivo CSV, permitindo preservar os sinais previamente processados e retomar a execução sem duplicação de documentos.

3.4 Construção do grafo

Após a estruturação e classificação dos sinais monetários, os dados foram inseridos em um banco de dados orientado a grafos utilizando o Neo4j. A modelagem adotada foi composta por dois tipos de nós: `Publication`, utilizado para representar cada comunicação do Federal Reserve, e `Signal`, utilizado para representar individualmente os sinais de política monetária extraídos dessas comunicações.

Os nós `Publication` foram identificados de forma única pela URL da publicação. Para cada nó, foram armazenadas as propriedades `title` e `publication_date`, correspondentes, respectivamente, ao título e à data de publicação do documento. O uso da URL como identificador permitiu que diferentes sinais extraídos de uma mesma comunicação fossem associados a um único nó de publicação.

Os nós `Signal`, por sua vez, foram identificados pela combinação entre o conteúdo textual do sinal e a URL da publicação de origem. Dessa forma, sinais com conteúdos semelhantes ou mesmo idênticos, mas provenientes de documentos distintos, puderam ser mantidos como entidades independentes no grafo. Cada nó recebeu as propriedades `classification`, `score`, `justification`, `evidence`, `embedding_signal` e `date`. A propriedade `date` corresponde à data de publicação do documento do qual o sinal foi extraído.

A vinculação entre as publicações e os sinais foi representada pela relação `HAS_SIGNAL`, criada entre cada nó `Publication` e os respectivos nós `Signal`. Essa estrutura preserva a origem documental de cada sinal e, em conjunto com as propriedades `justification` e `evidence`, permite rastrear a classificação até o conteúdo da comunicação utilizada pelo modelo de linguagem.

Além das relações entre publicações e sinais, foram construídas relações `SIMILAR_TO` entre sinais semanticamente próximos. Essas conexões foram obtidas a partir da comparação dos vetores armazenados em `embedding_signal` e receberam a propriedade `score_similarity`, correspondente à similaridade entre os respectivos vetores. Como a proximidade semântica representa uma associação simétrica, a direção das relações foi desconsiderada nas projeções utilizadas nas análises de rede.

Diferentemente dos nós e das relações `HAS_SIGNAL`, que constituem a estrutura permanente do grafo, as relações `SIMILAR_TO` foram reconstruídas separadamente para cada período de análise. Antes do processamento de um novo período, as relações desse tipo existentes eram removidas e uma nova rede de similaridade era criada contendo apenas os sinais pertencentes ao intervalo temporal considerado. A definição desses períodos e o

procedimento utilizado para estabelecer as conexões semânticas são apresentados na seção seguinte.

Essa estrutura é ilustrada na Figura 2.



Figura 2. Esquema dos nós e das relações utilizados na construção do grafo.

Fonte: Autoria própria.

3.5 Caracterização das redes por período

A construção das relações `SIMILAR_TO` foi realizada separadamente para cada intervalo de análise. Essa estratégia restringiu as comparações semânticas aos sinais associados ao mesmo período entre reuniões consecutivas do FOMC, evitando a formação de relações entre sinais pertencentes a contextos temporais distintos.

As datas que delimitam os períodos foram obtidas da base textual produzida nas etapas anteriores. Foram selecionadas as publicações cujo título correspondia exatamente a *Federal Reserve issues FOMC statement*, referentes aos comunicados oficiais divulgados após as reuniões do FOMC. As respectivas datas de publicação foram reunidas, eventuais duplicidades foram eliminadas e os valores foram ordenados cronologicamente.

A partir dessa sequência, cada intervalo foi definido por duas datas consecutivas de divulgação dos comunicados do FOMC. Para um período iniciado em t_i e encerrado em t_{i+1} , foram selecionados os nós `Signal` que possuíam a propriedade `embedding_signal` e cuja data satisfazia a condição

$$t_i \leq \text{data de publicação} < t_{i+1}.$$

Consequentemente, as comunicações publicadas na data inicial foram incluídas no período, enquanto aquelas divulgadas na data do comunicado subsequente foram excluídas. Essa definição evita que o indicador referente ao intervalo incorpore informações publicadas simultaneamente à decisão do FOMC utilizada posteriormente como referência para sua avaliação, preservando o caráter prospectivo da análise.

A quantidade de sinais monetários disponíveis para a construção da rede variou entre os períodos analisados, em função do número e do conteúdo das comunicações publicadas entre reuniões consecutivas do FOMC. A Figura 3 apresenta o número de nós `Signal`

selecionados em cada intervalo. Cada nó corresponde a um sinal monetário extraído das comunicações publicadas entre a data inicial do período, inclusive, e a data do comunicado subsequente, exclusive.




Figura 3. Número de sinais monetários utilizados na construção da rede em cada período entre comunicados consecutivos do FOMC.

Fonte: Autoria própria.

A variação no número de nós evidencia que a quantidade de informações disponíveis para a construção das redes não é constante ao longo do tempo. Sendo que o mínimo de sinais disponíveis ocorre nas reuniões realizadas no começo da pandemia de COVID-19.

Para cada intervalo, os sinais selecionados foram projetados temporariamente em memória por meio do Neo4j Graph Data Science (GDS). Na primeira projeção, denominada *signal-cypher*, foram incluídos apenas os nós *Signal* pertencentes ao período e a propriedade vetorial *embedding_signal*. Essa projeção não altera a estrutura persistida no banco de dados e foi utilizada exclusivamente como entrada para o cálculo das relações de similaridade.

Sobre essa projeção foi executado o algoritmo *k*-nearest neighbors (KNN). A comparação entre os sinais foi realizada utilizando a similaridade do cosseno aplicada aos vetores de *embedding*. Para cada nó, foram considerados no máximo 50 vizinhos semanticamente mais próximos (*topK* = 50), sujeitos também a um limiar mínimo de similaridade.

O procedimento retornou, para cada conexão selecionada, os identificadores dos dois nós e o respectivo valor de similaridade. Esses identificadores foram convertidos novamente nos nós *Signal* armazenados no Neo4j. Para impedir a criação duplicada de uma mesma associação, os pares foram filtrados de acordo com seus identificadores internos antes da persistência da relação. Para cada par mantido, foi criada uma relação *SIMILAR_T0*, e o valor calculado pelo KNN foi armazenado na propriedade *score_similarity*.

O limiar mínimo de similaridade foi determinado de forma adaptativa para cada período. O procedimento foi iniciado com valor igual a 0,80. Após a construção das relações, uma nova projeção, denominada *signal-wcc*, foi formada com os nós e as conexões daquele intervalo, considerando as relações como não direcionadas. Em seguida, foi aplicado o algoritmo de componentes fracamente conectadas (*Weakly Connected Components* - WCC) para determinar o número de componentes conexas existentes na rede.

Quando mais de uma componente era identificada, o limiar de similaridade era reduzido em 0,01 e as relações SIMILAR_T0 eram reconstruídas. O procedimento era repetido até que todos os nós do período pertencessem a uma única componente conexa ou até que fosse atingido o limite mínimo de 0,10. Dessa forma, para cada período foi selecionado o maior limiar, dentro da sequência testada, capaz de produzir uma rede conectada.

Esse procedimento procurou estabelecer um equilíbrio entre duas características da rede. Limiares elevados preservam apenas relações de maior proximidade semântica, porém podem produzir grupos isolados de sinais. A redução progressiva do limiar adiciona conexões menos semelhantes até que seja obtida uma estrutura conectada.

Ao final do procedimento, cada intervalo entre comunicados consecutivos do FOMC foi representado por uma rede semântica ponderada. Os nós correspondem aos sinais monetários identificados nas comunicações publicadas durante o período, enquanto as relações representam sua proximidade semântica e são ponderadas pela propriedade *score_similarity*. Essa representação constitui a entrada para os algoritmos de detecção de comunidades e de centralidade empregados na construção dos indicadores de orientação monetária.

Os limiares de similaridade obtidos pelo procedimento adaptativo variaram entre os períodos analisados, refletindo diferenças na estrutura semântica dos sinais disponíveis em cada intervalo. A Figura 4 apresenta o valor do limiar necessário para que a rede correspondente a cada período formasse uma única componente conexa.




Figura 4. Limiar de similaridade utilizado na construção da rede em cada período entre comunicados consecutivos do FOMC.

Fonte: Autoria própria.

Os resultados mostram que não foi necessário utilizar o mesmo nível mínimo de similaridade em todos os períodos para obter uma rede conectada. Um limiar mais elevado indica que os diferentes documentos apresentam pontos de vista mais próximos entre si, permitindo conectar os sinais com relações de maior proximidade semântica e preservando uma rede mais coesa quanto ao conteúdo abordado. Em contraste, um limiar mais baixo indica maior dispersão entre os pontos de vista expressos nos documentos: para formar uma única rede, foi necessário incorporar relações entre sinais progressivamente menos semelhantes. Assim, o limiar sintetiza o grau de convergência semântica necessário para conectar os sinais produzidos no período, sem representar diretamente a orientação favorável ou contrária da política monetária.

Além da abordagem com limiar de similaridade adaptativo, foi avaliada uma segunda configuração utilizando um limiar constante para todos os períodos. Para definir esse valor, foi calculada a mediana dos limiares de similaridade obtidos individualmente pelo procedimento adaptativo ao longo dos intervalos analisados. A mediana resultante foi igual a 0,72. Valor adotado como limiar fixo no segundo cenário. Essa escolha permite utilizar um valor representativo dos limiares requeridos para a formação das redes no procedimento adaptativo, ao mesmo tempo em que mantém constante o critério de conexão entre os sinais ao longo de toda a série temporal.

4 Conclusão

In this work we used Phasellus vitae dui eget leo tristique accumsan nec quis purus. In ac dapibus risus. Curabitur feugiat massa in aliquet tincidunt. Morbi congue quis lorem vitae finibus. Vestibulum euismod nunc et est bibendum rutrum. Maecenas lorem enim, porttitor eu justo eget, lacinia rutrum massa. Quisque id commodo arcu.

Referências

- Barrat, A.; Barthélemy, M.; Pastor-Satorras, R.; Vespignani, A., 2004 The architecture of complex weighted networks. *Proceedings of the National Academy of Sciences* 101(11): 3747–3752.
- Blinder, A. S.; Ehrmann, M.; Fratzscher, M.; de Haan, J.; Jansen, D.-J., 2008 Central bank communication and monetary policy: A survey of theory and evidence. *Journal of Economic Literature* 46(4): 910–945.
- Brown, T.; Mann, B.; Ryder, N.; Subbiah, M.; Kaplan, J. D.; Dhariwal, P.; Neelakantan, A.; Shyam, P.; Sastry, G.; Askell, A.; others, 2020 Language models are few-shot learners. *Advances in neural information processing systems* 33: 1877–1901.
- Freeman, L. C., 1977 A set of measures of centrality based on betweenness. *Sociometry* 40(1): 35–41.
- Gentzkow, M.; Kelly, B.; Taddy, M., 2019 Text as data. *Journal of Economic Literature* 57(3): 535–574, American Economic Association 2014 Broadway, Suite 305, Nashville, TN 37203-2425.
- Gil, A. C., 2010 Como elaborar projetos de pesquisa. Atlas, São Paulo, SP, Brasil, fifth edition.
- Gürkaynak, R. S.; Sack, B.; Swanson, E. T., 2005 Do actions speak louder than words? the response of asset prices to monetary policy actions and statements. *International Journal of Central Banking* 1(1): 55–93.
- Hansen, A. L.; Kazinnik, S., 2024 Can chatgpt decipher fedspeak? SSRN Working Paper No. 4399406.

-
- Loughran, T.; McDonald, B., 2011 When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of finance* 66(1): 35–65, Wiley Online Library.
- Needham, M.; Hodler, A. E., 2019 *Graph algorithms: practical examples in Apache Spark and Neo4j*. O'Reilly Media.
- Page, L.; Brin, S.; Motwani, R.; Winograd, T., 1999 The pagerank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab.
- Silva, T. C.; Moriya, K.; Veyrune, R. M., 2025 From text to quantified insights: A large-scale IIm analysis of central bank communication. IMF Working Paper 2025/109, International Monetary Fund.
- Traag, V. A.; Waltman, L.; van Eck, N. J., 2019 From louvain to leiden: Guaranteeing well-connected communities. *Scientific Reports* 9(1): 5233.
- Woodford, M., 2005 Central bank communication and policy effectiveness. Technical Report 11898, National Bureau of Economic Research.